Retos y dificultades

Cuando descubres que el verdadero enemigo no es el algoritmo, sino tu propio dataset lleno de basura

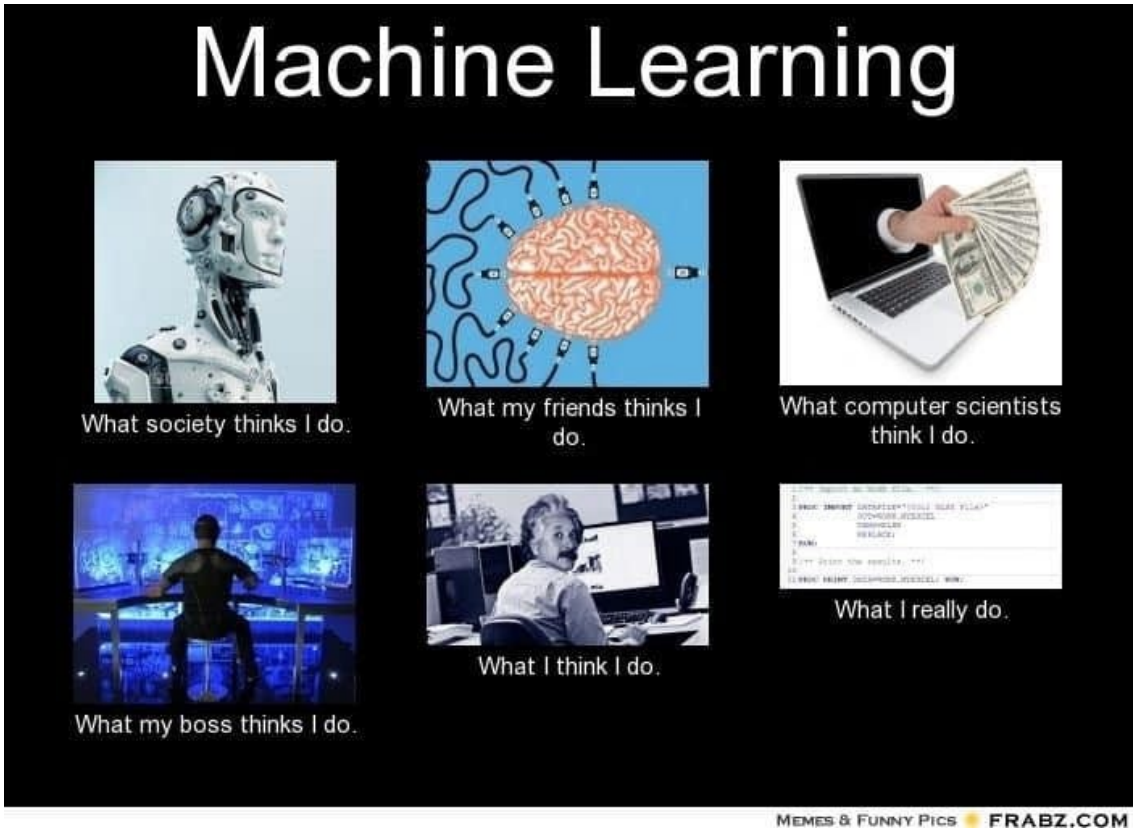
Daniel Barajas Higuera

MLEARN



Retos y dificultades del aprendizaje automático

La tarea principal es seleccionar un modelo y entrenarlo con algunos datos, las dos cosas que pueden salir mal son un "modelo deficiente" y "datos deficientes". A continuación, se presentan algunos ejemplos de datos deficientes.



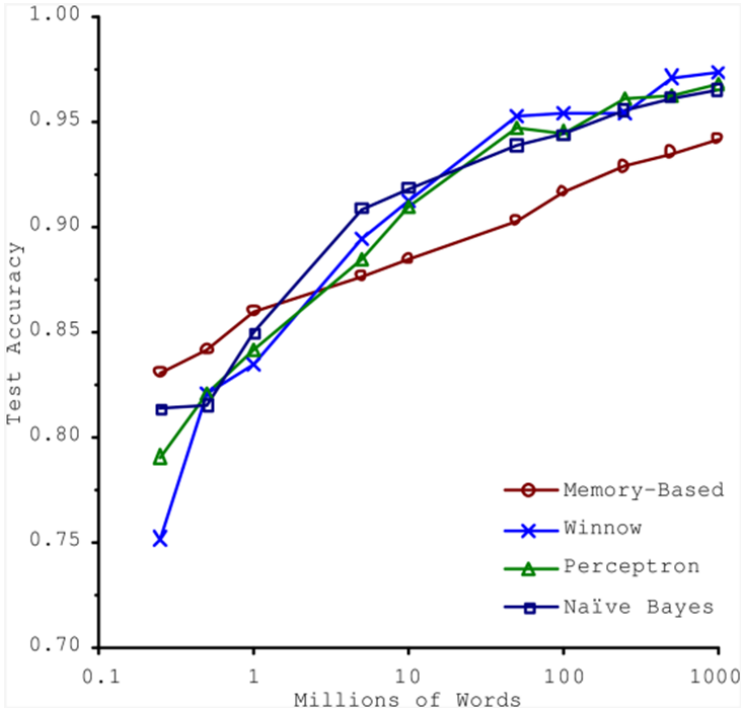
Contenido

1. Insuficiente cantidad de datos de entrenamiento
2. Datos no representativos
3. Mala calidad de los datos
4. Características Irrelevantes
5. Overfitting
6. Underfitting
7. Overfitting vs Underfitting

Insuficiente cantidad de datos de entrenamiento

El aprendizaje automático aún no es tan eficiente; la mayoría de los algoritmos de aprendizaje automático requieren muchos datos para funcionar correctamente.
Incluso para problemas simples, se necesitan típicamente miles de ejemplos, y para problemas complejos como el reconocimiento de imágenes o voz, pueden ser necesarios millones de ejemplos (a menos que se reutilicen partes de un modelo existente).

Insuficiente cantidad de datos de entrenamiento



En 2001 los investigadores de Microsoft Michele Banko y Eric Brill demostraron que algoritmos de AprendizajeAutomático muy diferentes, incluyendo algunos bastante simples, funcionaban casi de manera idéntica en un problema complejo de desambiguación del lenguaje natural una vez que se les proporcionaba suficientes datos.

Insuficiente cantidad de datos de entrenamiento



The data you expected



The data you got

Contenido

1. Insuficiente cantidad de datos de entrenamiento
2. Datos no representativos
3. Mala calidad de los datos
4. Características Irrelevantes
5. Overfitting
6. Underfitting
7. Overfitting vs Underfitting

Datos no representativos

Para que un modelo de aprendizaje generalice correctamente, debe ser entrenado con datos que cubran una variedad representativa de los casos que enfrentará.
Si los datos de entrenamiento no incluyen ciertos grupos o situaciones, el modelo tendrá dificultades para hacer predicciones válidas fuera de ese rango.

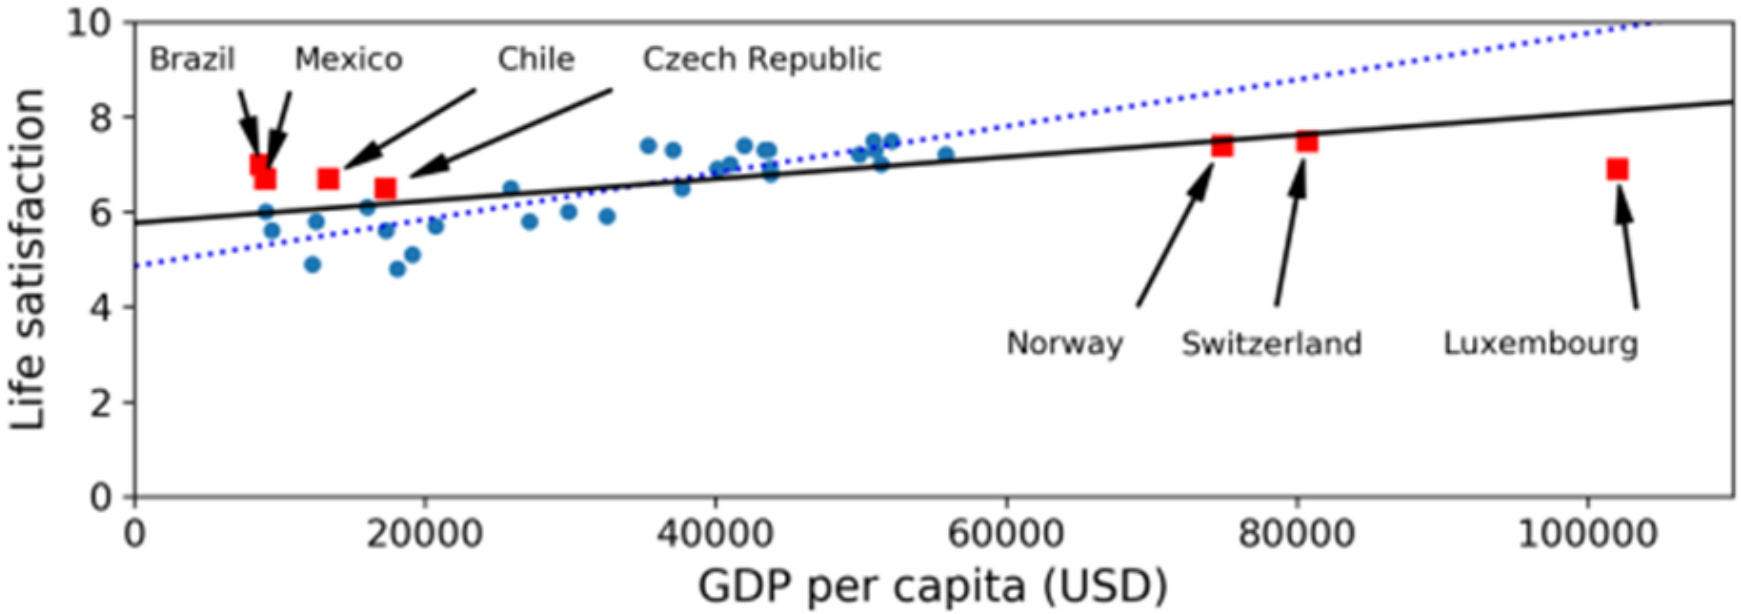
Ejemplo: predicción de felicidad según el PIB

En este caso, se entrenó un modelo lineal con datos de países que tienen un PIB per cápita entre $23,500 y $62,500.
Este conjunto de entrenamiento no incluye países muy pobres ni muy ricos, por lo tanto, la línea de regresión resultante (discontinua) refleja una relación sesgada: mayor PIB implica mayor felicidad.

Cómo cambia el modelo con datos representativos

Al incluir países con PIB muy bajo y muy alto, la línea de regresión (sólida) cambia notablemente.
Esto muestra que:

- Un modelo lineal simple no captura bien la relación completa.
- Países muy ricos no necesariamente son más felices.
- Algunos países pobres reportan niveles altos de felicidad.



Datos no representativos

Supongamos que se desea construir un sistema para reconocer videos de música electrónica. Una forma de crear el conjunto de entrenamiento es buscar "música electrónica" en YouTube y usar los videos resultantes.
Sin embargo, esto asume que el motor de búsqueda de YouTube devuelve un conjunto de videos representativo de todos los videos de música electrónica en la plataforma.
En realidad, los resultados de búsqueda probablemente estarán sesgados hacia artistas populares (y si la búsqueda se realiza en Colombia, aparecerán muchos videos de "electrónica urbana", que suenan muy diferentes a artistas como Daft Punk).
Por otro lado, ¿cómo se podría obtener un conjunto de entrenamiento grande de otra manera?

Contenido

1. Insuficiente cantidad de datos de entrenamiento
2. Datos no representativos
3. Mala calidad de los datos
4. Características Irrelevantes
5. Overfitting
6. Underfitting
7. Overfitting vs Underfitting

Mala calidad de los datos

Si los datos de entrenamiento contienen errores, valores atípicos o ruido, el sistema tendrá dificultades para detectar patrones, afectando su rendimiento. Limpiar los datos es esencial y muchos científicos de datos dedican mucho tiempo a esta tarea.
Ejemplos de limpieza de datos:

- Descartar o corregir manualmente instancias claramente atípicas.
- Decidir cómo manejar características faltantes, ya sea ignorarlas, rellenarlas o entrenar modelos con y sin ellas.



Mala calidad de los datos



Contenido

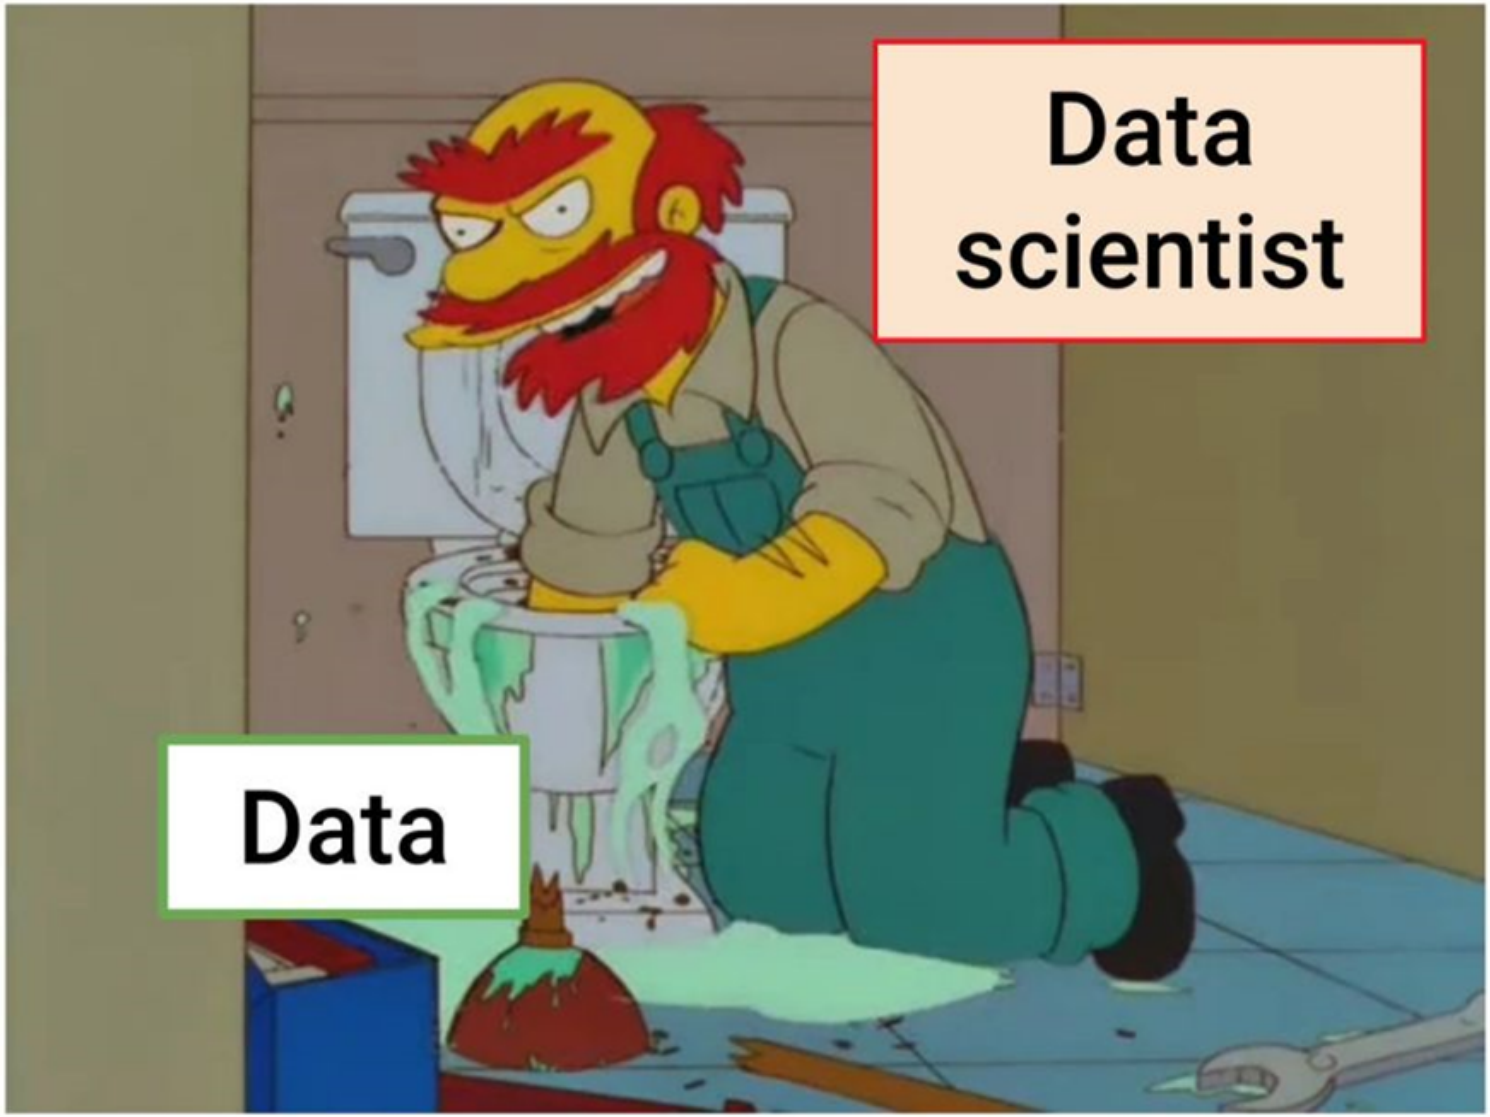
1. Insuficiente cantidad de datos de entrenamiento
2. Datos no representativos
3. Mala calidad de los datos
4. Características Irrelevantes
5. Overfitting
6. Underfitting
7. Overfitting vs Underfitting

Características Irrelevantes

Una parte crítica del éxito de un proyecto de Aprendizaje Automático es idear un buen conjunto de características en las que entrenar. Este proceso, llamado ingeniería de características (*feature engineering*), implica los siguientes pasos:

- Selección de características (*Feature selection*): seleccionar las características más útiles entre las características existentes.
- Extracción de características (*Feature extraction*): combinar características existentes para producir una más útil.
- Creación de nuevas características mediante la recopilación de nuevos datos.

Características Irrelevantes

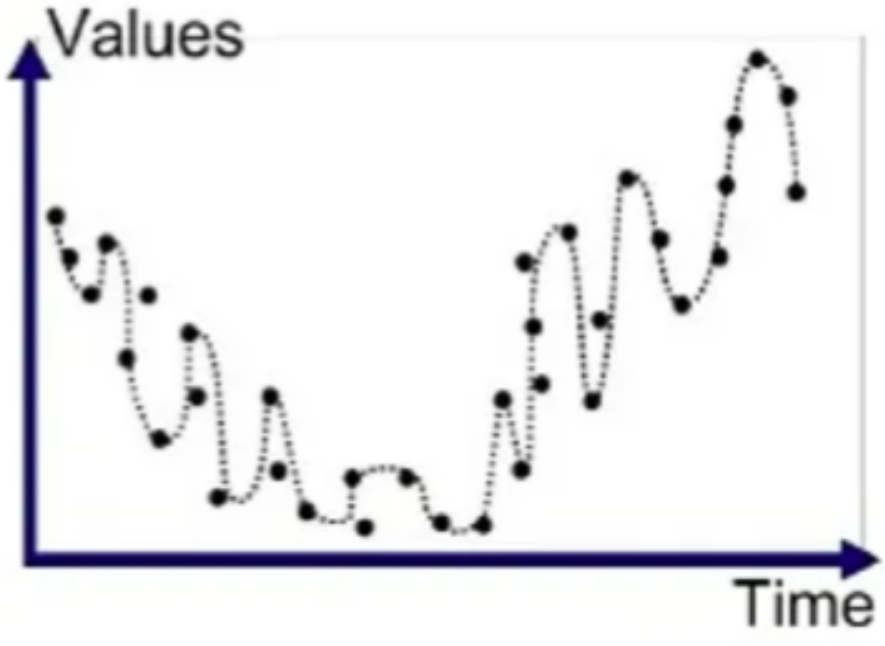


Contenido

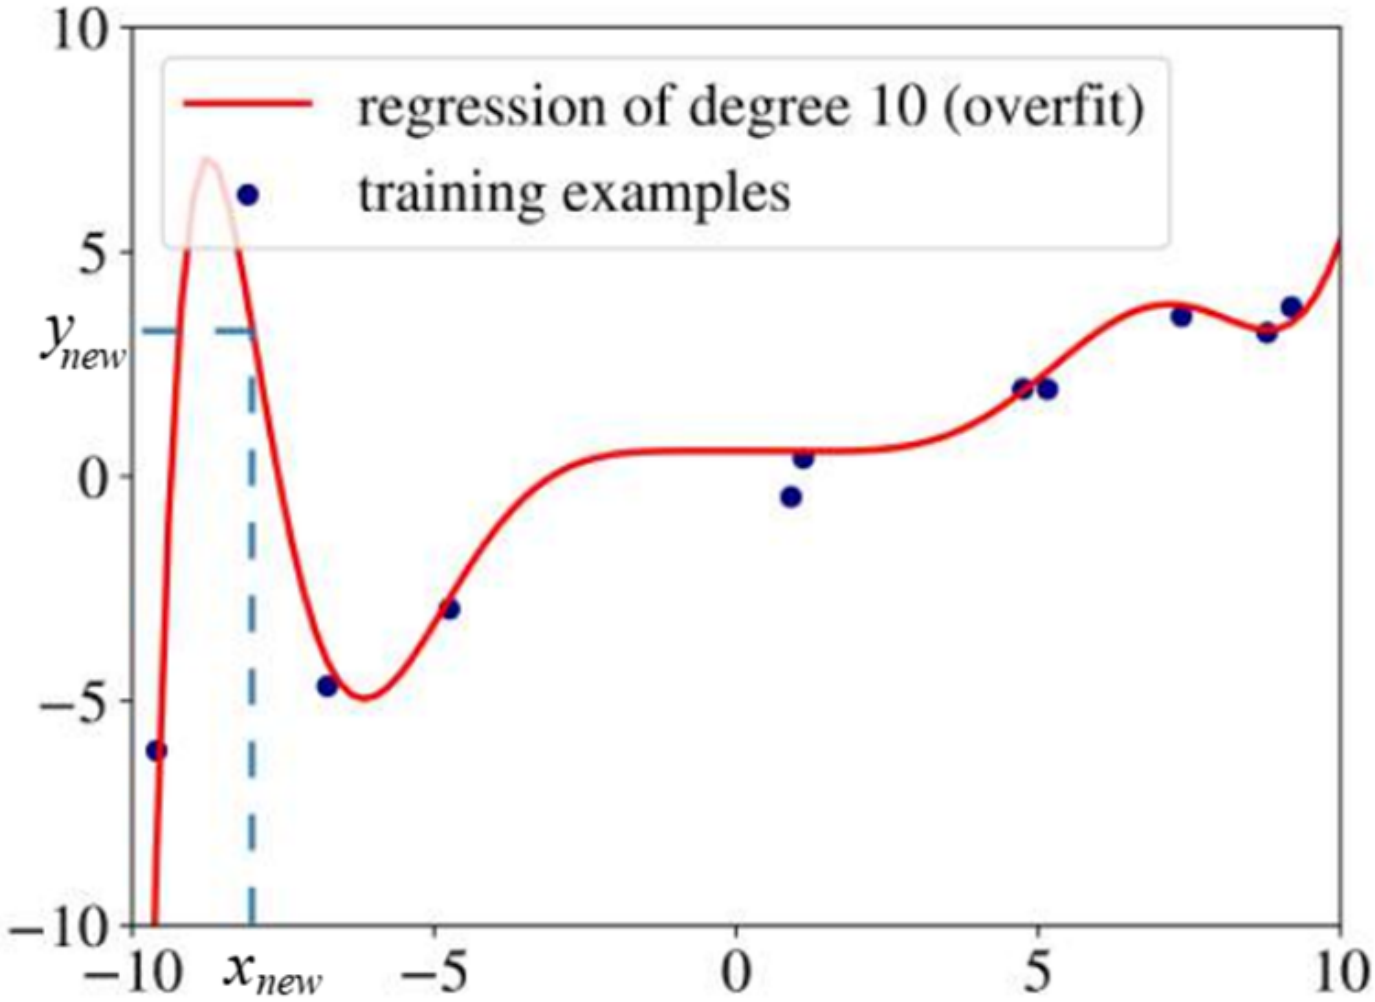
1. Insuficiente cantidad de datos de entrenamiento
2. Datos no representativos
3. Mala calidad de los datos
4. Características Irrelevantes
5. Overfitting
   - Posibles soluciones:
6. Underfitting
7. Overfitting vs Underfitting

Overfitting

El sobreajuste ocurre cuando el modelo es demasiado complejo en relación con la cantidad y el ruido de los datos de entrenamiento



Overfitting



Posibles soluciones para corregir el sobreajuste

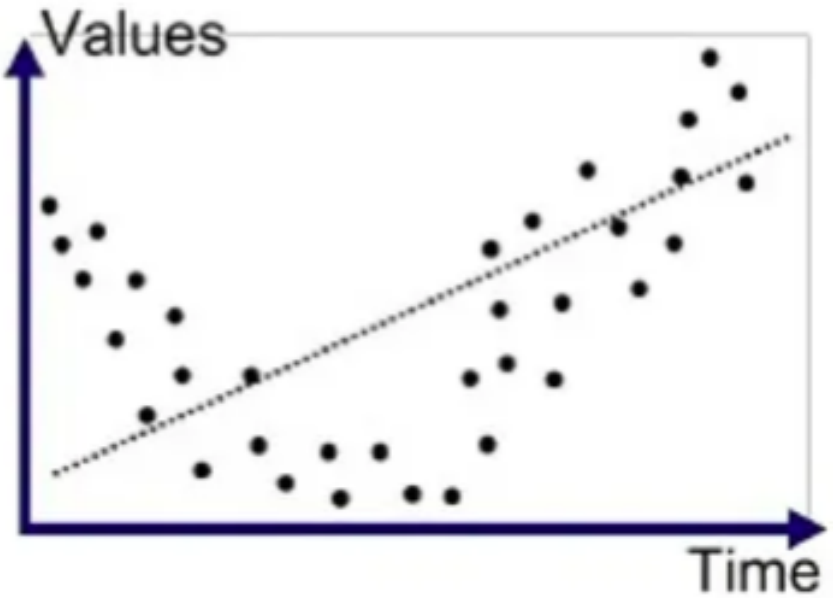
- Simplificar el modelo seleccionando uno con menos parámetros (por ejemplo, un modelo lineal en lugar de un modelo polinómico de alto grado), reduciendo el número de atributos en los datos de entrenamiento o limitando el modelo.
- Recopilar más datos de entrenamiento.
- Reducir el ruido en los datos de entrenamiento (por ejemplo, corrigiendo errores de datos y eliminando valores atípicos).

Contenido

1. Insuficiente cantidad de datos de entrenamiento
2. Datos no representativos
3. Mala calidad de los datos
4. Características Irrelevantes
5. Overfitting
6. Underfitting
   - **Opciones para corregir el subajuste:**
7. Overfitting vs Underfitting

Underfitting

El subajuste es lo opuesto del sobreajuste: ocurre cuando el modelo es demasiado simple para aprender la estructura subyacente de los datos. Por ejemplo, un modelo lineal de satisfacción con la vida tiende a subajustar, ya que la realidad es más compleja que el modelo, y sus predicciones serán inexactas incluso en los ejemplos de entrenamiento.



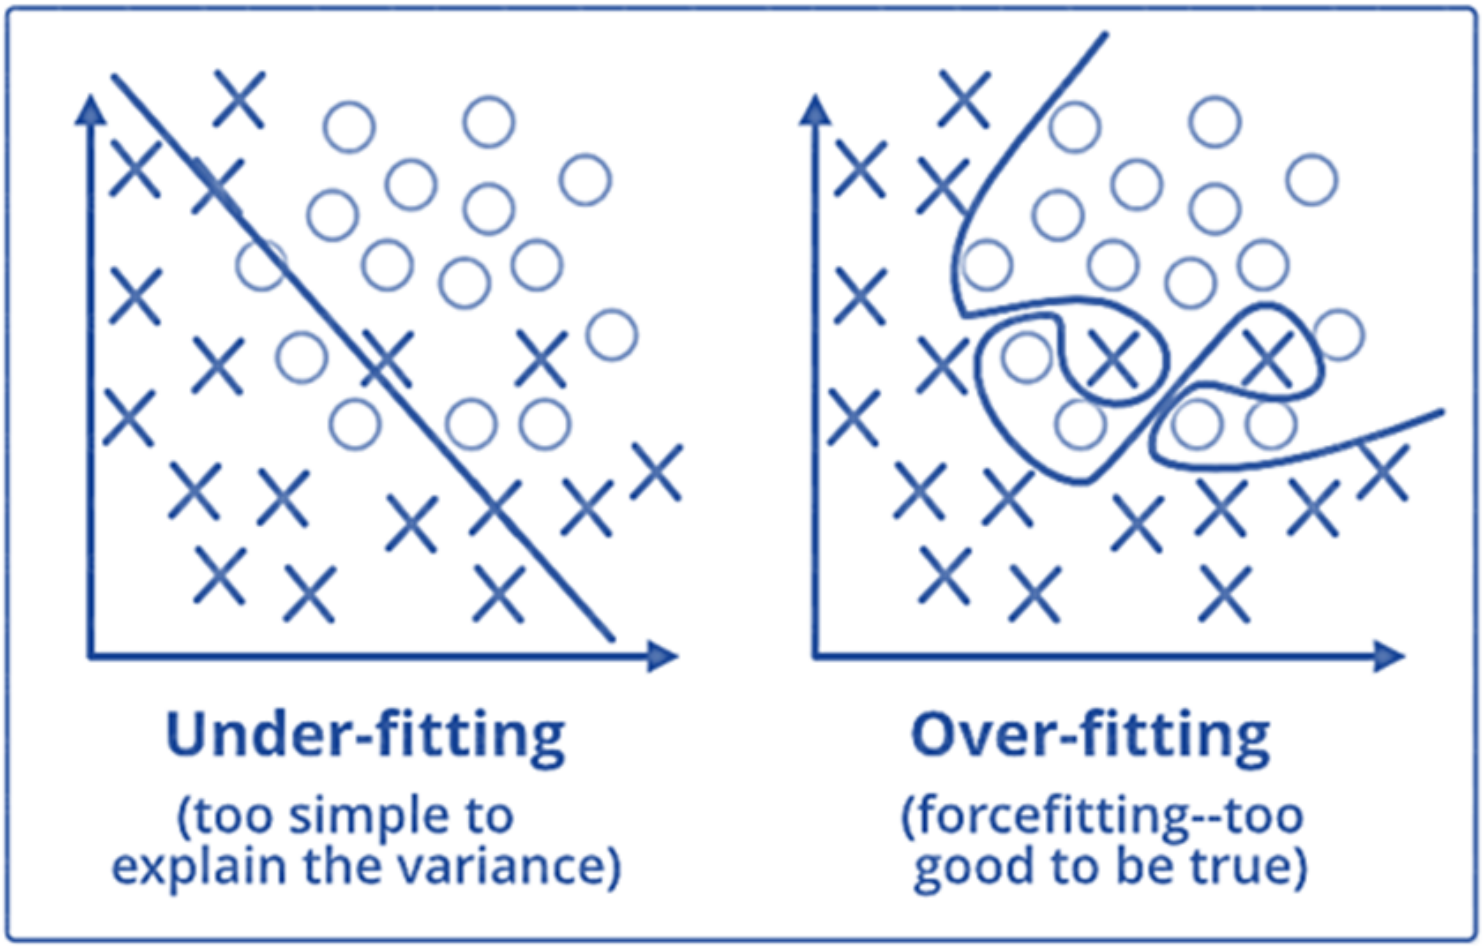
Opciones para corregir el subajuste

- Seleccionar un modelo más potente, con más parámetros.
- Proporcionar mejores características al algoritmo de aprendizaje (ingeniería de características).
- Reducir las restricciones en el modelo (por ejemplo, reduciendo el hiperparámetro de regularización).

Contenido

1. Insuficiente cantidad de datos de entrenamiento
2. Datos no representativos
3. Mala calidad de los datos
4. Características Irrelevantes
5. Overfitting
6. Underfitting
7. Overfitting vs Underfitting

Overfitting vs Underfitting



Overfitting vs Underfitting

