

Aprendizaje Supervisado: Regresión Lineal

Una línea, demasiadas expectativas.

Daniel Barajas Higuera

MLEARN



Contenido

- 1 Precios de viviendas
- 2 Aprendizaje Supervisado
- 3 Regresión

Ejemplo de aprendizaje supervisado


Comencemos hablando de algunos ejemplos de problemas de aprendizaje supervisado. Supongamos que tenemos un conjunto de datos con las áreas habitables y los precios de 23 apartamentos en Bogotá:

Área (m ²)	Precio (millones \$)
157	2084
170	1300
44	213
99	615
129	1528
⋮	⋮

Visualización de datos

Podemos representar gráficamente estos datos:

Precio (millones) vs. Area



Predicción de precios de viviendas

Dado un conjunto de datos como este, ¿cómo podemos aprender a predecir los precios de otros apartamentos en Bogotá, en función del tamaño de su área habitable?

Usaremos $x^{(i)}$ para denotar las variables de entrada (área habitable en este ejemplo), también llamadas *características*, y $y^{(i)}$ para denotar la variable de salida o *objetivo* que queremos predecir (precio).

Un par $(x^{(i)}, y^{(i)})$ se llama *ejemplo de entrenamiento*, y el conjunto de datos que utilizaremos para aprender —una lista de n ejemplos de entrenamiento $\{(x^{(i)}, y^{(i)}); i = 1, \dots, n\}$ — se llama *conjunto de entrenamiento*.

Predicción de precios de viviendas

- Objetivo: predecir el precio de apartamentos en Bogotá según su área habitable.
- $x^{(i)}$: variables de entrada (*características*), como área habitable.
- $y^{(i)}$: variable de salida (*objetivo*), el precio.
- Ejemplo de entrenamiento: par $(x^{(i)}, y^{(i)})$.
- Conjunto de entrenamiento: lista de m ejemplos $\{(x^{(i)}, y^{(i)})\}_{i=1}^m$.


Contenido

- 1 Precios de viviendas
- 2 **Aprendizaje Supervisado**
- 3 Regresión

Notación y espacios de valores

- El superíndice (i) indica la posición en el conjunto de entrenamiento (no es potencia).
- $\mathcal{X}$: espacio de valores de entrada.
- $\mathcal{Y}$: espacio de valores de salida.
- En este ejemplo: $\mathcal{X} = \mathcal{Y} = \mathbb{R}$.
- Objetivo: aprender una función $h : \mathcal{X} \mapsto \mathcal{Y}$ que prediga bien y .
- A h se le llama *hipótesis*.

Proceso de aprendizaje supervisado



Regresión vs Clasificación

Cuando la variable objetivo que intentamos predecir es continua, como en nuestro ejemplo de viviendas, el problema se llama de **regresión**. Cuando y puede tomar solo un número pequeño de valores discretos (por ejemplo, si dado el área habitable queremos predecir si la vivienda es una apartamento o un apartamento), se llama un problema de **clasificación**.

Vectores de entrada y variables objetivo

Las x son vectores bidimensionales en $\mathbb{R}^2$. Por ejemplo, $x_1^{(i)}$ es el área habitable de la i -ésima vivienda en el conjunto de entrenamiento, y $x_2^{(i)}$ es su número de habitaciones.

En general, al diseñar un problema de aprendizaje, se decide qué características incluir (chimenea, número de baños, etc.). Por ahora, tomamos las características tal como están dadas.

Contenido

- 1 Precios de viviendas
- 2 Aprendizaje Supervisado
- 3 Regresión**

Función de hipótesis

Para aprendizaje supervisado debemos representar las funciones o hipótesis h en la computadora. Como primera aproximación, supongamos que y es una función lineal de x :

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2$$

Los θ_i son **parámetros** (o *pesos*) que determinan la función lineal que mapea de $\mathcal{X}$ a $\mathcal{Y}$.

¿Por qué es un problema de regresión?

- Variable objetivo: y es el **precio** de la vivienda, magnitud *continua* ($y \in \mathbb{R}^+$).
- Objetivo del modelo: **estimar un valor numérico**, no asignar una etiqueta discreta.
- Entradas: $x \in \mathbb{R}^2$ (área habitable, número de habitaciones), características cuantitativas.
- Hipótesis usada: $h_\theta : \mathbb{R}^2 \rightarrow \mathbb{R}$, por ejemplo $h_\theta(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2$.
- Evaluación típica: MSE, RMSE; no hay fronteras de decisión ni clases.

Notación simplificada

Quitamos el subíndice θ y escribimos simplemente $h(x)$. Definimos $x_0 = 1$ (término independiente), por lo que:

$$h(x) = \sum_{i=0}^d \theta_i x_i = \theta^T x$$

Aquí, θ y x son vectores, y d es el número de variables de entrada (sin contar x_0).

Función de costo

Queremos que $h(x)$ esté lo más cerca posible de y en los ejemplos de entrenamiento. Definimos la **función de costo**:

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2$$

Esta es la función de costo de *mínimos cuadrados ordinarios*, ampliamente usada en regresión lineal.

Resumen

- La notación simplificada nos permite expresar el modelo de regresión lineal como $h(x) = \theta^T x$.
- La función de costo $J(\theta)$ mide qué tan bien se ajusta el modelo a los datos.
- Luego veremos cómo **minimizar** $J(\theta)$ utilizando métodos de optimización como el *gradiente descendente*.

That's All

