

# Gradiente Descendente

Gradient Descent Wears Prada.

Daniel Barajas Higuera

MLEARN



# Contenido

---

## 1 Gradiente descendente

# Introducción al Gradiente Descendente

---

El **gradiente descendente** es un algoritmo de optimización iterativo que busca minimizar una función de costo moviéndose en la dirección del gradiente negativo.

- Se usa en machine learning para encontrar parámetros óptimos.
- Funciona ajustando los valores en pasos proporcionales a la pendiente de la función.
- La tasa de aprendizaje ( $\alpha$ ) controla la magnitud de cada ajuste.

Matemáticamente, se actualiza un parámetro  $\theta$  siguiendo la regla:

$$\theta \leftarrow \theta - \alpha \nabla J(\theta)$$

donde  $J(\theta)$  es la función de costo.

## Problema: Minimizar los errores de Andy en *Runway*

---

En *The Devil wears Prada*, Andy Ahumada llega a Runway buscando una oportunidad en el periodismo, aunque no le interesa la moda.



## Problema: Minimizar los errores de Andy en *Runway*

---

Andy acepta el trabajo como asistente de Miranda Rúa Priestly porque le promete abrir puertas en la industria editorial.



# Problema: Minimizar los errores de Andy en *Runway*

Cuando Andy empieza en *Runway*, comete muchos errores. Podemos modelar su desempeño con una función de pérdida:

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{error}_i^2$$

Su objetivo es minimizar esta función, igual que en aprendizaje automático minimizamos la pérdida de un modelo.

- Al principio, su desempeño es bajo.
- Debe reducir sus errores para mejorar.
- Esto se traduce en minimizar la función de pérdida.



# El gradiente: Nigel y Miranda como “derivadas”

---

El gradiente indica qué tan rápido cambia la pérdida según los parámetros:

$$\nabla J(\theta) = \frac{\partial J}{\partial \theta}$$



# El gradiente: Nigel y Miranda como “derivadas”

---

- Nigel (estilista) y Miranda (jefa) actúan como el gradiente.
- Le dicen en qué falla y cómo mejorar.
- Sin retroalimentación, Andy seguiría cometiendo errores.





# Problema de minimización y dirección del cambio

---

- Objetivo en ML: encontrar  $\theta^* = \arg \min_{\theta} J(\theta)$ .
- $J(\theta)$  mide el error; se desea reducirlo en cada iteración.
- El gradiente  $\nabla_{\theta} J(\theta)$  apunta al mayor incremento local de  $J$ .
- Para disminuir  $J$ : moverse en la dirección opuesta al gradiente.



# Método de máximo descenso

---

- Idea clásica: avanzar en  $-\nabla_{\theta} J(\theta)$ .
- La tasa de aprendizaje  $\alpha > 0$  controla el tamaño del paso.
- Intuición práctica: retroalimentación  $\rightarrow$  ajuste controlado  $\rightarrow$  menor error.



# Expansión de Taylor

---

**Univariable** (alrededor de  $x_0$ ):

$$f(x_0 + \Delta x) \approx f(x_0) + f'(x_0) \Delta x$$

**Multivariable** (alrededor de  $\theta$ ):

$$J(\theta + \Delta\theta) \approx J(\theta) + \nabla_{\theta} J(\theta)^{\top} \Delta\theta$$

- Para pasos pequeños, el término lineal domina.
- Minimizar  $J$  localmente  $\Rightarrow$  elegir  $\Delta\theta$  opuesto a  $\nabla_{\theta} J(\theta)$ .

# Regla de actualización

- Paso propuesto:  $\Delta\theta = -\alpha \nabla_{\theta} J(\theta)$ .  
$$\theta^{(t+1)} = \theta^{(t)} - \alpha \nabla_{\theta} J(\theta^{(t)})$$



# La actualización de Andy: pequeños pasos hacia el óptimo

---

El gradiente descendente actualiza los parámetros así:

$$\theta = \theta - \alpha \nabla J(\theta)$$

- $\theta$ : estilo y actitud de Andy.
- $\alpha$ : qué tan rápido sigue los consejos.
- $\nabla J(\theta)$ : dirección de mejora.

# Iteraciones: La evolución de Andy

---

Andy mejora de forma progresiva:

- Primera iteración: Cambia los zapatos y peina su cabello.

Si  $\alpha$  es muy grande, cambia demasiado rápido y falla. Si  $\alpha$  es muy pequeño, tarda demasiado en mejorar.



# Iteraciones: La evolución de Andy

---

- Segunda iteración: Usa ropa de diseñador.



# Iteraciones: La evolución de Andy

---

- Tercera iteración: Gana confianza y se transforma por completo.

Con cada paso, se acerca a su mejor versión.





# Convergencia: cuando Andy alcanza su mejor versión


---

El gradiente descendente se detiene cuando:

$$\nabla J(\theta) \approx 0$$

- Sabe cómo vestirse.
- Entiende la moda.
- Se desenvuelve con confianza.

Esto es encontrar el mínimo de la función de pérdida.




# Visualizando el proceso de optimización

---



# Visualizando el proceso de optimización



- Andy inicia en un punto alto (alto error).
- Desciende siguiendo el gradiente (retroalimentación de Nigel).
- Alcanza el mínimo global (su mejor versión en moda).

# Resumen: Andy como un modelo de Machine Learning

---

| Concepto en aprendizaje automático | Analogía en El Diablo Viste a la Moda  |
|------------------------------------|----------------------------------------|
| Función de pérdida $J(\theta)$     | Errores de Andy en <i>Runway</i>       |
| Gradiente $\nabla J(\theta)$       | Retroalimentación de Nigel y Miranda   |
| Parámetros $\theta$                | Estilo y actitud de Andy               |
| Tasa de aprendizaje $\alpha$       | Qué tan rápido sigue los consejos      |
| Iteraciones                        | Cambios progresivos en su estilo       |
| Convergencia                       | Andy se vuelve una profesional en moda |

# Conclusión

---

- Andy sigue un proceso iterativo de aprendizaje, igual que el gradiente descendente.
- Recibe retroalimentación, ajusta sus decisiones y mejora.
- Encuentra su versión óptima, así como un modelo minimiza su error.
- El gradiente descendente es la clave para mejorar, tanto en aprendizaje automático como en la moda.

