

Algoritmo Mínimos Cuadrados

Restar errores como si fueran deudas, solo para darte cuenta de que el saldo nunca llega a cero

Daniel Barajas Higuera

MLEARN



Contenido

- 1 Regresión
- 2 Mínimos cuadrados
- 3 Algoritmo

Modelo y notación

- Modelo de regresión lineal:

$$h(x) = \sum_{i=0}^d \theta_i x_i = \theta^T x$$

- $x_0 = 1$ representa el término independiente.
- θ y x son vectores; d es el número de variables de entrada (sin contar x_0).

Función de costo

- Medimos el ajuste del modelo con:

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2$$

- Esta es la función de *mínimos cuadrados ordinarios*.
- Próximo paso: aprenderemos a **minimizar** $J(\theta)$ usando gradiente descendente.

Contenido

- 1 Regresión
- 2 Mínimos cuadrados**
- 3 Algoritmo

Algoritmo LMS (Least Mean Squares)

Queremos elegir θ para minimizar $J(\theta)$. Para ello, usamos un algoritmo de búsqueda que inicia con un valor inicial para θ y que lo actualiza repetidamente para hacer $J(\theta)$ más pequeño, hasta converger a un valor que lo minimice.

Consideremos el algoritmo de **descenso de gradiente**, que parte de un θ inicial y repite la actualización:

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$

Esta actualización se hace para todos los $j = 0, \dots, d$. El parámetro α es la **tasa de aprendizaje** (*learning rate*), que controla el tamaño del paso en la dirección de mayor descenso de J .

Derivada parcial: paso a paso

Partimos de la definición para un solo ejemplo:

$$\frac{\partial}{\partial \theta_j} J(\theta) = \frac{\partial}{\partial \theta_j} \frac{1}{2} (h_{\theta}(x) - y)^2$$

Aplicamos la regla de la cadena y la potencia:

$$= 2 \cdot \frac{1}{2} (h_{\theta}(x) - y) \frac{\partial}{\partial \theta_j} (h_{\theta}(x) - y)$$

Como y no depende de θ , su derivada es cero:

$$= (h_{\theta}(x) - y) \frac{\partial}{\partial \theta_j} h_{\theta}(x)$$

Cierre de la derivación

Recordemos que:

$$h_{\theta}(x) = \sum_{i=0}^d \theta_i x_i$$

Por linealidad de la derivada y considerando que x es constante respecto a θ :

$$\frac{\partial}{\partial \theta_j} h_{\theta}(x) = \frac{\partial}{\partial \theta_j} \sum_{i=0}^d \theta_i x_i = x_j$$

Sustituyendo:

$$\frac{\partial}{\partial \theta_j} J(\theta) = (h_{\theta}(x) - y) x_j$$

Derivada parcial para un ejemplo

Si tenemos solo un ejemplo de entrenamiento (x, y) , la derivada parcial es:

$$\begin{aligned}\frac{\partial}{\partial \theta_j} J(\theta) &= \frac{\partial}{\partial \theta_j} \frac{1}{2} (h_{\theta}(x) - y)^2 \\ &= (h_{\theta}(x) - y) \cdot x_j\end{aligned}$$

donde $h_{\theta}(x) = \sum_{i=0}^d \theta_i x_i$.

Contenido

- 1 Regresión
- 2 Mínimos cuadrados
- 3 Algoritmo**

Algoritmo de gradiente descendente para regresión lineal

- 1 Inicializar θ_j para $j = 0, \dots, d$ (por ejemplo, en cero).
- 2 Repetir hasta converger:

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right) x_j^{(i)}, \quad \forall j$$

- 3 Donde:

- α es la tasa de aprendizaje.
- m es el número de ejemplos.
- $h_{\theta}(x) = \theta^T x$.

Gradiente descendente en Julia

```
function gradiente_descendente(X, y,  $\alpha$ , iteraciones)
    m, d = size(X)
     $\theta$  = zeros(d)
    for _ in 1:iteraciones
        pred = X *  $\theta$ 
        for j in 1:d
             $\theta[j]$  -=  $\alpha$  * (1/m) * sum((pred - y) .* X[:, j])
        end
    end
    return  $\theta$ 
end
```

Datos de precios de Apartamentos en Bogotá

Área (m ²)	Precio (millones \$)
157	2084
170	1300
44	213
99	615
129	1528
⋮	⋮

Ejemplo de uso en Julia

```
# Datos: área (m²) y precio (millones)
```

```
 $\alpha$  = 0.0001
```

```
iteraciones = 1000
```

```
 $\theta$  = gradiente_descendente(X, y,  $\alpha$ , iteraciones)
```

```
println("Parámetros aprendidos: ",  $\theta$ )
```

Datos para regresión lineal multivariable

Área (m ²)	Habitaciones	Parqueadero	Piso	Precio (millones \$)
157	3	3	5	2084
170	3	1	5	1300
44	2	1	13	213
99	3	1	6	615
129	3	1	5	1528
⋮	⋮	⋮	⋮	⋮

Tareita ...

Necesito el dataset completo de **2000 apartamentos** en Bogotá. Con Área (m^2), Habitaciones, Parqueadero, Piso, Precio... y si tiene vista a Monserrate.



Bueno... ahora que ya son casi estadísticos y saben hacer webscraping con Python, y sobrevivieron al curso de **Optimización**, no debería ser un problema, ¿verdad?