

Supuestos de la Regresión Lineal


Reglas invisibles que todos rompen, nadie admite y que hacen escandalizar a los estadísticos teóricos como si fuera herejía

Daniel Barajas Higuera

MLEARN



Supuestos



¿Qué es la Regresión Lineal?

- Técnica para modelar la relación entre una variable dependiente (continua) y una o más variables independientes.
- **Tipos:**
 - **Simple:** Una sola variable independiente (e.g., predecir price usando carat).
 - **Múltiple:** Varias variables independientes (e.g., predecir price usando carat, cut, y clarity).

Supuestos de la Regresión Lineal

Los supuestos de la regresión lineal aseguran que los resultados del modelo sean válidos y confiables.


- Garantizan que las predicciones sean precisas.
- Evitan resultados sesgados o inexactos.
- Permiten interpretar adecuadamente los coeficientes del modelo.

Supuestos de la Regresión Lineal

- 1 **Linealidad**
- 2 **No colinealidad**
- 3 **Homocedasticidad**
- 4 **Independencia de los errores**
- 5 **Normalidad de los errores**

Supuesto 1: Linealidad

- Existe una relación lineal entre las variables independientes (x) y la dependiente (y).
- Si no hay linealidad, el modelo no puede capturar correctamente la relación subyacente.
- Evaluación inicial:
 - Gráficos de dispersión (x vs. y).



Supuesto 1: Linealidad (Evaluación)

- **Evaluación adicional:** Dom asume que “más carreras $\Rightarrow$ más problemas familiares” en línea recta. Letty revisa **residuos vs. ajustados** para confirmar que no haya giros de guion. Si aparecen patrones en U o S, se rompe el supuesto de linealidad.
- **Implicación en predicción:** Si la relación no es lineal, el modelo promete control y termina en choque: predicciones sesgadas, fallas al extrapolar, como un derrape mal calculado.



Linealidad en ML

Aquí nadie se muere si la relación no es recta: se lanzan polinomios, interacciones o se cambia de modelo sin drama. La métrica manda, no un altar geométrico.





Estadística Clásica



Machine Learning


Supuesto 2: Homocedasticidad

- La varianza de los errores debe ser constante para todos los valores de x .
- La heterocedasticidad puede hacer que las predicciones sean menos confiables.
- Evaluación inicial:
 - Gráfico de residuos vs. valores ajustados.




Supuesto 2: Homocedasticidad (Evaluación)

- **Evaluación adicional:** Brian busca explosiones del mismo tamaño a cualquier velocidad en **residuos vs. ajustados**. Aplica la **prueba de Breusch–Pagan** para verificarlo. Si el nitro explota más a altas velocidades, hay heterocedasticidad.
- **Implicación en predicción:** Con varianza no constante, los intervalos tiemblan: más incertidumbre y menos precisión justo cuando más se necesita.



Homoscedasticidad en ML

Varianza desigual: molesta a puristas, no a predictores. Si estorba, se pondera, transforma o modela; mientras tanto, el modelo sigue andando.




Estadística Clásica



Machine Learning


Supuesto 3: Independencia de los Errores

- Los errores (ε) deben ser independientes, sin autocorrelación.
- Crucial en datos temporales o secuenciales.
- Evaluación inicial:
 - Gráficos de residuos para identificar patrones.



Supuesto 3: Independencia de los Errores (Evaluación)

- **Evaluación adicional:** Roman verifica con **Durbin–Watson** y correlogramas que los choques de hoy no predigan los de mañana. Si hay autocorrelación, los errores se persiguen en caravana.
- **Implicación en predicción:** Sin independencia, los errores se encadenan. El modelo confunde inercia con señal y repite el mismo derrape una y otra vez.



Independencia en ML

Las observaciones se pegan y se influyen; lo relevante es validar bien para que el brillo del R^2 no sea maquillaje barato.




Estadística Clásica



Machine Learning


Supuesto 4: Falta de Multicolinealidad

- Las variables independientes no deben estar altamente correlacionadas.
- La colinealidad dificulta determinar el impacto individual de cada variable.
- Evaluación inicial:
 - Matriz de correlación.



Supuesto 4: Falta de Multicolinealidad (Evaluación)

- **Evaluación adicional:** Letty calcula **VIF** y revisa la matriz de correlación. Evita que dos variables sean el mismo auto con pintura distinta. VIF altos significan que los predictores compiten por el mismo rol.
- **Implicación en predicción:** El modelo puede predecir, pero interpretar betas es como conducir con el volante flojo: pequeños cambios en datos mueven grandes cambios en coeficientes.



Multicolinealidad en ML

Coeficientes inestables, sí; pero con regularización, selección o proyecciones, la predicción sigue y las lágrimas se reservan para la interpretación.



Estadística Clásica



Machine Learning

Supuesto 5: Normalidad de los Errores

- Los errores deben seguir una distribución normal.
- Relevante para intervalos de confianza y pruebas estadísticas.
- Evaluación inicial:
 - Histogramas y gráficos Q-Q de residuos.



$X_1 \neq X_2$



$X_1 \sim X_2$


Supuesto 5: Normalidad de los Errores (Evaluación)

- **Evaluación adicional:** La brisa milagrosa no arregla todo: se revisan **histogramas y Q-Q**, y si hace falta, la prueba de **Shapiro–Wilk**. Si los residuos tienen colas pesadas, la distribución no es normal.
- **Implicación en predicción:** La normalidad afecta la inferencia. Predicciones puntuales pueden sobrevivir, pero la confianza en intervalos y tests se desploma.



Normalidad de los errores en ML

Normalidad para predicción: irrelevante. Importa en inferencia; aquí se optimiza desempeño y se ignoran rituales.





Estadística Clásica



Machine Learning

Revisión Extra: Valores Atípicos

- Los valores atípicos son observaciones que se desvían mucho del resto de los datos.
- Pueden distorsionar los coeficientes y predicciones.
- Evaluación inicial:
 - Gráficos de dispersión (x vs. y).



Valores Atípicos (Evaluación)

- **Evaluación adicional:** Se buscan “stunts imposibles” con **IQR**, leverage o distancia de Cook. Un solo dato extremo puede jalar la recta como si fuera un auto volando en CGI barato.
- **Implicación en predicción:** Los outliers distorsionan betas y reducen precisión. Decisión final: limpiar, robustecer o convertirlo en spin-off dentro del modelo.



Valores Atípicos en Regresión ML

Los outliers no siempre son ruido decorativo: en modelos lineales pueden sesgar los coeficientes y hacer que la recta se incline hacia un solo punto extraño.

- **Impacto en la predicción:** Un dato raro puede inflar el error global y bajar la métrica aunque el resto del ajuste sea bueno.
- **Efecto colateral:** El modelo intenta “complacer” a un caso que jamás se repetirá en test ni en producción.



Por qué tener cuidado en ML

En machine learning robusto los outliers suelen diluirse, pero en regresión lineal básica son como dinamita: un solo punto puede torcer todo el modelo.

- **Decisión práctica:**
 - Si es error de captura → se limpia.
 - Si es real pero extremo → se modela aparte o se usan técnicas robustas.
- **Idea clave:** ignorar un outlier en ML no siempre rompe el modelo, pero dejarlo sin revisar en regresión puede costar métricas, interpretaciones y credibilidad.



Regresión Lineal

