Regresión Logística

La pesadilla estadística donde cada probabilidad es una premonición, y el 0.5 decide si mueres en el examen o solo quedas hospitalizado

Daniel Barajas Higuera

MLEARN



Contenido

1. Clasificación
2. Máxima verosimilitud
3. La sigmoide y el destino
4. Algoritmo

Aprendizaje supervisado y clasificación

En Machine Learning, dentro del **aprendizaje supervisado** encontramos:

- **Regresión**: variable respuesta continua.
- **Clasificación**: variable respuesta categórica (clases).

Problema desmotivador: decidir si un estudiante es aceptado al curso de deep learning o no en el próximo semestre. Este es un caso de **clasificación binaria**.

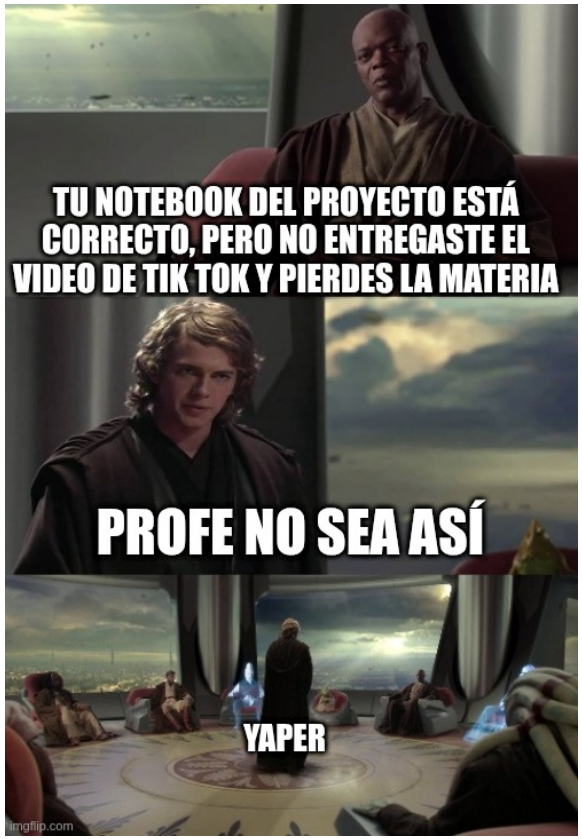
Caso motivador: aspirante Jedi

Problema: predecir si un aspirante es **aceptado** por el consejo. Variables predictoras:

- **Midiclorianos**
- **Entrenamiento**
- **Fuerza**

Variable de respuesta:

$$Y = \begin{cases} 1 & \text{Aceptado} \\ 0 & \text{No aceptado} \end{cases}$$



Datos del consejo (aspirante Jedi)

Midiclorianos	Entrenamiento	Fuerza	Respuesta
12	3	6	0
13	4	4	1
13	4	6	0
12	9	9	1
14	4	5	1
14	4	4	0
17	2	2	0
17	6	5	1
20	5	7	1
20	9	3	0

Contenido

1. Clasificación
2. Máxima verosimilitud
3. La sigmoide y el destino
4. Algoritmo

Verosimilitud en regresión logística

Modelo (probabilidad logística):

$$p_i = \frac{e^{\beta^\top x^{(i)}}}{1 + e^{\beta^\top x^{(i)}}}$$

La **verosimilitud** cuantifica la probabilidad conjunta de las observaciones observadas según los parámetros β:

$$L(\beta) = \prod_{i=1}^{m} p_i^{y^{(i)}} (1 - p_i)^{1 - y^{(i)}}$$

Verosimilitud por observación

Para cada observación, la contribución a la verosimilitud es:

$$L_i(\beta) = \begin{cases} p_i, & y^{(i)} = 1 \\ 1 - p_i, & y^{(i)} = 0 \end{cases} \qquad p_i = \frac{e^{\beta^\top x^{(i)}}}{1 + e^{\beta^\top x^{(i)}}}$$

La verosimilitud total resulta del producto:

$$L(\beta) = \prod_{i=1}^{m} L_i(\beta).$$

Log-verosimilitud

Al aplicar logaritmo, el producto se convierte en suma:

$$\ell(\beta) = \ln L(\beta) = \sum_{i=1}^{m} \ln L_i(\beta).$$

Expresado en términos de la probabilidad p_i:

$$\ell(\beta) = \sum_{i=1}^{m} \left[y^{(i)} \ln p_i + (1 - y^{(i)}) \ln(1 - p_i) \right].$$

Máxima verosimilitud

La estimación por máxima verosimilitud busca:

$$\hat{\beta} = \arg\max_{\beta} \ell(\beta).$$

El objetivo es encontrar los parámetros que alinean al modelo con los datos observados.

Cálculos en la hoja log1

- **Combinación lineal:** definir z como suma ponderada de las variables predictoras.

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n$$

- **Transformación exponencial:** obtener la exponencial del logit.

$$e^z$$

- **Probabilidad:** aplicar función logística condicional.

$$p = \begin{cases} \dfrac{e^z}{1+e^z}, & \text{si } y = 1 \\ 1 - \dfrac{e^z}{1+e^z}, & \text{si } y = 0 \end{cases}$$

- **Log-likelihood:** calcular el logaritmo natural de la probabilidad observada.

$$\ln(p)$$

Un respiro visual

CUANDO MAXIMIZAS LA VEROSIMILITUD...



Y SIENTES QUE LOS DATOS FLUYEN CON LA FUERZA

Contenido

1. Clasificación
2. Máxima verosimilitud
3. La sigmoide y el destino
4. Algoritmo

Caso motivador: destino inevitable

Problema: predecir si una persona **sobrevive** o no frente a un destino que parece imposible de esquivar. Variables predictoras:

- **Presagios** (señales previas que anuncian riesgo)

Caso motivador: destino inevitable

Problema: predecir si una persona **sobrevive** o no frente a un destino que parece imposible de esquivar. Variables predictoras:

- **Presagios** (señales previas que anuncian riesgo)
- **Contactos** (interacciones con otros)

Caso motivador: destino inevitable

Problema: predecir si una persona **sobrevive** o no frente a un destino que parece imposible de esquivar. Variables predictoras:

- **Presagios** (señales previas que anuncian riesgo)
- **Contactos** (interacciones con otros)
- **EvitaObjetos** (intentos de escapar al accidente)

Caso motivador: destino inevitable

Problema: predecir si una persona **sobrevive** o no frente a un destino que parece imposible de esquivar. Variables predictoras:

- **Presagios** (señales previas que anuncian riesgo)
- **Contactos** (interacciones con otros)
- **EvitaObjetos** (intentos de escapar al accidente)



Caso motivador: destino inevitable

Problema: predecir si una persona **sobrevive** o no frente a un destino que parece imposible de esquivar. Variables predictoras:

- **Presagios** (señales previas que anuncian riesgo)
- **Contactos** (interacciones con otros)
- **EvitaObjetos** (intentos de escapar al accidente)

Variable de respuesta:



Caso motivador: destino inevitable

Problema: predecir si una persona **sobrevive** o no frente a un destino que parece imposible de esquivar. Variables predictoras:

- **Presagios** (señales previas que anuncian riesgo)
- **Contactos** (interacciones con otros)
- **EvitaObjetos** (intentos de escapar al accidente)

Variable de respuesta:

$$Y = \begin{cases} 1 & \text{Sobrevive} \\ 0 & \text{No sobrevive} \end{cases}$$



Datos de personas

Presagios	Contactos	EvitaObjetos	Sobrevive
12	3	6	0
13	4	4	1
13	4	6	0
12	9	9	1
14	4	5	1
14	4	4	0
17	2	2	0
17	6	5	1
20	5	7	1
20	9	3	0

Destino final: el problema de aprendizaje

En **Machine Learning**, la regresión lineal modela salidas numéricas:

$$\hat{y} = \theta^\top x$$

pero este esquema falla si el desenlace es binario: **sobrevive (1) o no sobrevive (0)**.

El **destino final** del personaje depende de transformar la evidencia lineal $z = \theta^\top x$ en una **premonición probabilística**.

Premonición: la función sigmoide

Definimos la hipótesis del modelo como:

$$h_\theta(x) = \sigma(\theta^\top x) = \frac{1}{1 + e^{-\theta^\top x}}$$

- Interpretable como la probabilidad de **sobrevivir**.
- Asegura que la salida esté siempre en el rango $[0, 1]$.
- Permite decisiones de vida o muerte comparando con un umbral.

La función sigmoide

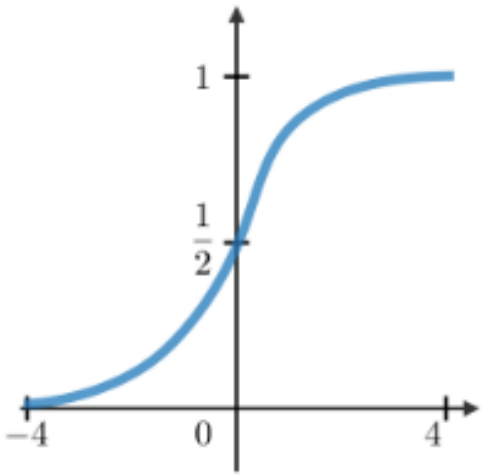
La **función sigmoide** transforma cualquier número real en un valor entre 0 y 1:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

- Su rango está acotado: $0 < \sigma(z) < 1$.
- Permite interpretar la salida como una **probabilidad**.
- Valores muy negativos $\rightarrow$ probabilidad cercana a 0.
- Valores muy positivos $\rightarrow$ probabilidad cercana a 1.
- Es continua y diferenciable, lo que facilita la optimización.

Sigmoid

$$g(z) = \frac{1}{1 + e^{-z}}$$



El castigo de tentar al destino

El aprendizaje requiere una función de **coste** que mida cuánto se equivocan nuestras premoniciones:

$$\text{costo}(h, y) = \begin{cases} -\log(h), & y = 1 \\ -\log(1-h), & y = 0 \end{cases}$$

- Predicciones seguras pero erradas pagan el precio más alto.
- Este criterio sustituye al error cuadrático de la regresión lineal.

Karma acumulado y conexión estadística

El coste global combina todos los casos en un único criterio:

$$J(\theta) = \frac{1}{m} \sum_{i=1}^{m} \Big[- y^{(i)} \log(h_\theta(x^{(i)})) - (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)})) \Big]$$

- **Karma acumulado**: la suma de todos los castigos.
- Coincide con el **negativo de la log-verosimilitud** en estadística clásica.
- Une la visión probabilística y la optimización del aprendizaje.

¿Por qué esta fórmula?

- Basada en la **entropía cruzada**: compara distribuciones de probabilidad.
- Los logaritmos hacen que los **errores fatales** se penalicen con dureza.
- La función es **convexa**: garantiza un único mínimo, incluso si las muertes parecen inevitables.
- En este escenario de **destino final**, el coste actúa como la cuenta pendiente: cada predicción equivocada suma al castigo acumulado, recordando que escapar tiene un precio.



Cálculos en la hoja log2 (ML)

- **Combinación lineal (logit):**

$$z = \theta^\top x = \theta_0 + \theta_1 x_1 + \cdots + \theta_n x_n$$

- **Hipótesis (Función sigmoide):**

$$h_\theta(x) = \sigma(z) = \frac{1}{1 + e^{-z}}$$

- **Costo para clase positiva ($y = 1$):**

$$-y \cdot \ln(h_\theta(x))$$

- **Costo para clase negativa ($y = 0$):**

$$-(1 - y) \cdot \ln(1 - h_\theta(x))$$

Nota: La suma de ambos componentes de entropía cruzada promediada sobre m observaciones define la función de costo $J(\theta)$.

Decisión de vida o muerte

Regla de predicción:

$$\hat{y}(x) = \begin{cases} 1, & \text{si } h_\theta(x) \geq 0{,}5 \quad \text{(Sobrevive)} \\ 0, & \text{si } h_\theta(x) < 0{,}5 \quad \text{(No sobrevive)} \end{cases}$$



Equivalencia de notaciones

Demostración de igualdad mediante el producto por $e^{-\beta^\top x}$ en numerador y denominador:

$$\frac{e^{\beta^\top x}}{1+e^{\beta^\top x}} \cdot \frac{e^{-\beta^\top x}}{e^{-\beta^\top x}} = \frac{1}{1+e^{-\beta^\top x}}$$

Comparación conceptual:

Atributo	**Estadística Clásica**	**Machine Learning**
Parámetro	β	θ
Función	Logit inversa	Sigmoide / Logística
Variable respuesta	p_i	$h_\theta(x)$ o $\sigma(z)$
Enfoque	Inferencia y significancia	Optimización y predicción

Conclusión: Ambas expresiones son matemáticamente idénticas. El cambio de notación responde únicamente a convenciones de cada disciplina.

El puente: estadística y Machine Learning

En **estadística clásica**, se estiman parámetros maximizando la **log-verosimilitud**:

$$\ell(\theta) = \sum_{i=1}^{m} \left[y^{(i)} \log(h_\theta(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)})) \right]$$

En **Machine Learning**, usamos el negativo:

$$J(\theta) = -\ell(\theta)$$

- Maximizar verosimilitud $\Leftrightarrow$ minimizar el coste.
- Dos lenguajes, un mismo principio.
- El **destino final** del modelo: probabilidades alineadas con los datos reales.

Contenido

1. Clasificación
2. Máxima verosimilitud
3. La sigmoide y el destino
4. Algoritmo

Escapando del destino con Gradiente Descendente

El aprendizaje ocurre ajustando parámetros en la dirección opuesta al gradiente:

$$\theta \leftarrow \theta - \alpha \nabla_\theta J(\theta).$$

Escapando del destino con Gradiente Descendente

El aprendizaje ocurre ajustando parámetros en la dirección opuesta al gradiente:

$$\theta \leftarrow \theta - \alpha \nabla_\theta J(\theta).$$

Gradiente en regresión logística:

$$\nabla_\theta J(\theta) = \frac{1}{m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right) x^{(i)}.$$

Escapando del destino con Gradiente Descendente

El aprendizaje ocurre ajustando parámetros en la dirección opuesta al gradiente:

$$\theta \leftarrow \theta - \alpha \nabla_\theta J(\theta).$$

Gradiente en regresión logística:

$$\nabla_\theta J(\theta) = \frac{1}{m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right) x^{(i)}.$$

En coordenadas:

$$\theta_j \leftarrow \theta_j - \alpha \frac{1}{m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right) x_j^{(i)}.$$

Convergencia: cuando ya no hay escape

Criterios típicos:

- Cambio pequeño en el coste: $|J^{(t)} - J^{(t-1)}| < \varepsilon$.
- Gradiente cercano a cero: $\|\nabla_\theta J^{(t)}\| < \varepsilon$.
- Límite de iteraciones o estancamiento.

Convergencia: cuando ya no hay escape

Criterios típicos:

- Cambio pequeño en el coste: $|J^{(t)} - J^{(t-1)}| < \varepsilon$.
- Gradiente cercano a cero: $\|\nabla_\theta J^{(t)}\| < \varepsilon$.
- Límite de iteraciones o estancamiento.

Buenas prácticas:

- Normalizar características.
- Monitorear la curva $J(\theta)$.
- Ajustar α si hay oscilaciones.

El ritual completo

1. Inicialice θ y fije α.

El ritual completo

1. Inicialice θ y fije α.
2. Para cada iteración: compute $h_\theta(x) = \sigma(\theta^\top x)$.

El ritual completo

1. Inicialice θ y fije α.
2. Para cada iteración: compute $h_\theta(x) = \sigma(\theta^\top x)$.
3. Evalúe el coste $J(\theta)$ y el gradiente $\nabla_\theta J(\theta)$.

El ritual completo

1. Inicialice θ y fije α.
2. Para cada iteración: compute $h_\theta(x) = \sigma(\theta^\top x)$.
3. Evalúe el coste $J(\theta)$ y el gradiente $\nabla_\theta J(\theta)$.
4. Actualice $\theta \leftarrow \theta - \alpha \nabla_\theta J(\theta)$.

El ritual completo

1. Inicialice θ y fije α.
2. Para cada iteración: compute $h_\theta(x) = \sigma(\theta^\top x)$.
3. Evalúe el coste $J(\theta)$ y el gradiente $\nabla_\theta J(\theta)$.
4. Actualice $\theta \leftarrow \theta - \alpha \nabla_\theta J(\theta)$.
5. Revise criterios de convergencia; si no se cumplen, repita.

El ritual completo

1. Inicialice θ y fije α.
2. Para cada iteración: compute $h_\theta(x) = \sigma(\theta^\top x)$.
3. Evalúe el coste $J(\theta)$ y el gradiente $\nabla_\theta J(\theta)$.
4. Actualice $\theta \leftarrow \theta - \alpha \nabla_\theta J(\theta)$.
5. Revise criterios de convergencia; si no se cumplen, repita.

Salida: parámetros finales $\theta^\star$ que minimizan J y definen la regla de decisión mediante $h_\theta(x)$ y el umbral τ.

El destino del modelo

- **Estadística clásica**: la verosimilitud dicta cómo debe alinearse el modelo con la evidencia.

El destino del modelo

- **Estadística clásica**: la verosimilitud dicta cómo debe alinearse el modelo con la evidencia.
- **Probabilidad**: la sigmoide transforma señales en premoniciones de vida o muerte.

El destino del modelo

- **Estadística clásica**: la verosimilitud dicta cómo debe alinearse el modelo con la evidencia.
- **Probabilidad**: la sigmoide transforma señales en premoniciones de vida o muerte.



El destino del modelo

- **Estadística clásica**: la verosimilitud dicta cómo debe alinearse el modelo con la evidencia.
- **Probabilidad**: la sigmoide transforma señales en premoniciones de vida o muerte.
- **Optimización**: el gradiente descendente guía la huida paso a paso, buscando el mínimo inevitable.



El destino del modelo

- **Estadística clásica**: la verosimilitud dicta cómo debe alinearse el modelo con la evidencia.
- **Probabilidad**: la sigmoide transforma señales en premoniciones de vida o muerte.
- **Optimización**: el gradiente descendente guía la huida paso a paso, buscando el mínimo inevitable.



En este **destino final**, el modelo sobrevive sólo si logra reducir su *karma acumulado*, anticipando los desenlaces con la mayor fidelidad posible.

Continuará...

EL DESTINO PARECÍA ESCRITO...



PERO LA MATRIZ DE CONFUSIÓN MOSTRARÁ COMO SE REPARTE LA TRAGEDIA