Support Vector Machine

El ritual oscuro donde los datos se alinean como luces de Navidad, mientras el margen amenaza con abrir un portal al Upside Down

Daniel Barajas Higuera



Contenido

1. Soporte Vectorial en Hawkins
2. Elementos clave
3. Support Vector Regression (SVR)
4. De vuelta a Hawkings

Inicio: anomalías en Hawkins

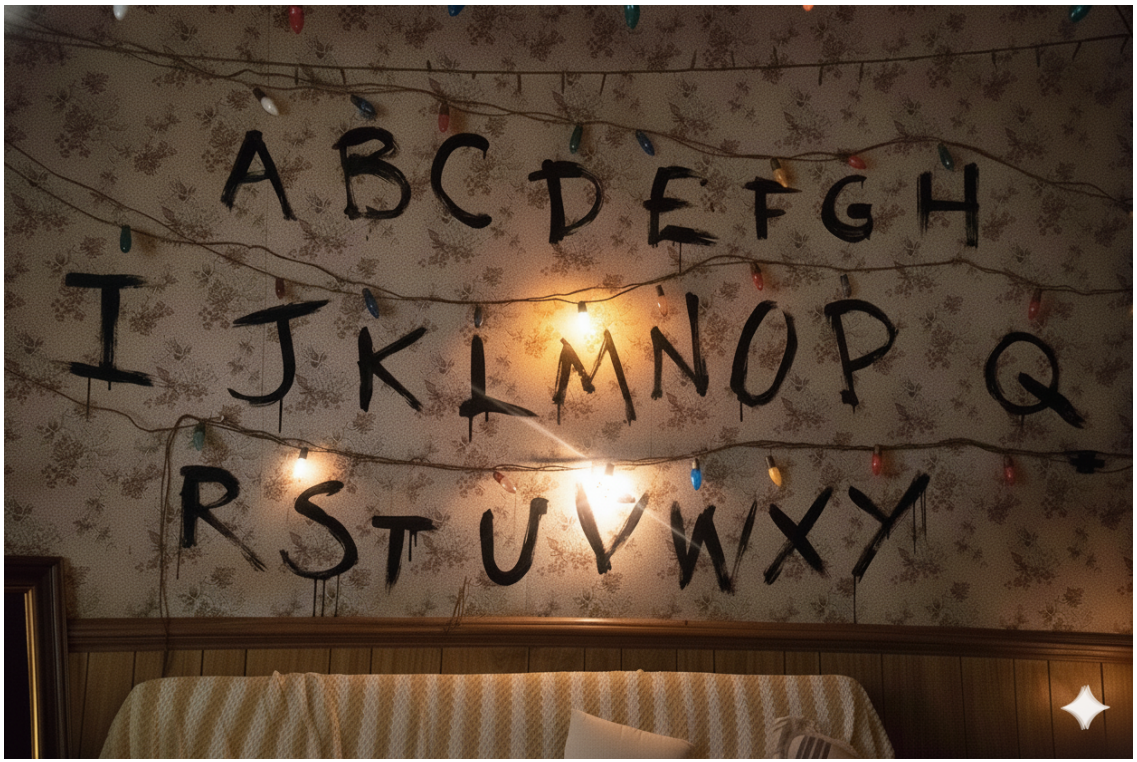
Hawkins parecía tranquila, hasta que los sensores del Laboratorio detectaron fluctuaciones en los campos eléctricos.
Cada evento se registró como un punto en un espacio de datos: energía, temperatura, vibración, tiempo.
Durante semanas los patrones fueron claros, hasta que aparecieron interferencias.
El mapa se llenó de puntos mezclados, humanos y criaturas del *Upside Down*.
Era imposible distinguirlos.



Inicio: anomalías en Hawkins

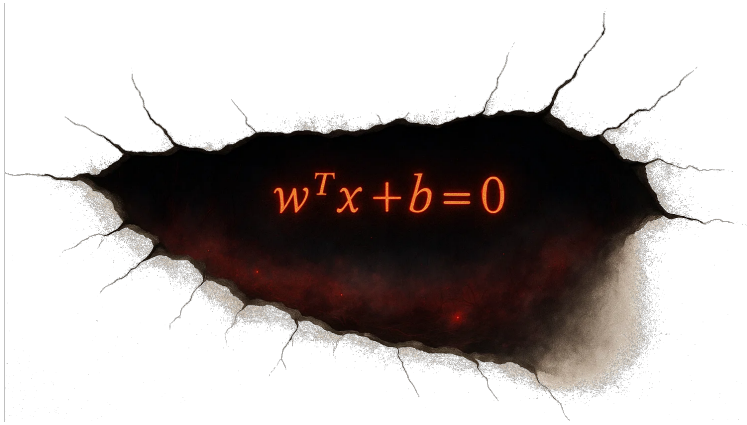
Los científicos comprendieron que necesitaban una frontera, una línea invisible capaz de mantener los mundos separados.

Así nació el proyecto **SVM —Support Vector Machine—**.



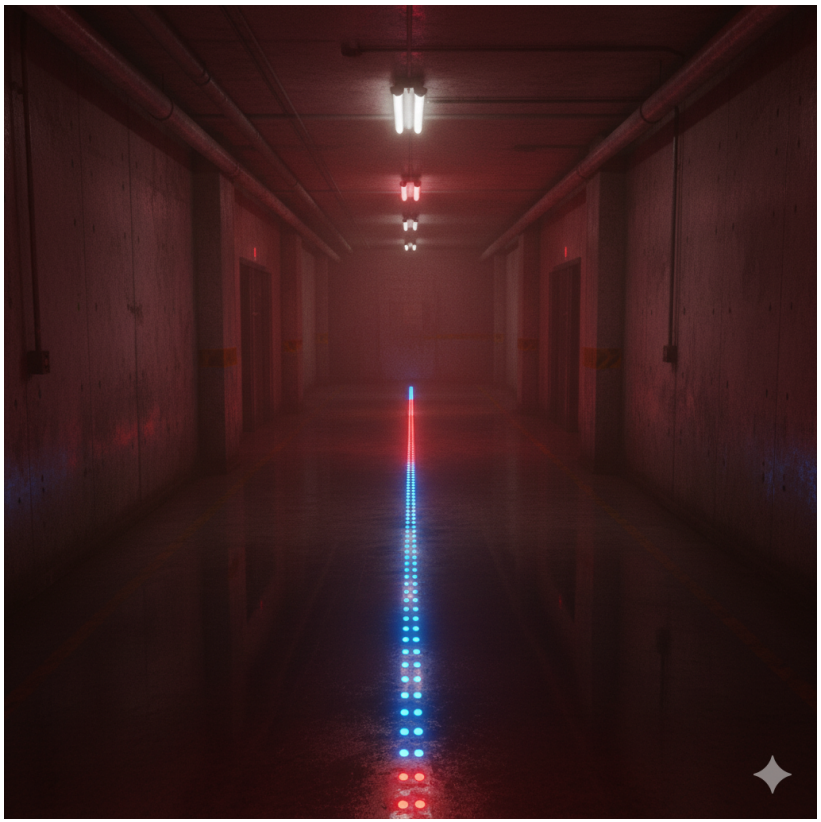
¿Qué es un hiperplano?

Un **hiperplano** es una generalización geométrica de una línea o un plano. Conjunto de puntos que satisfacen la ecuación:

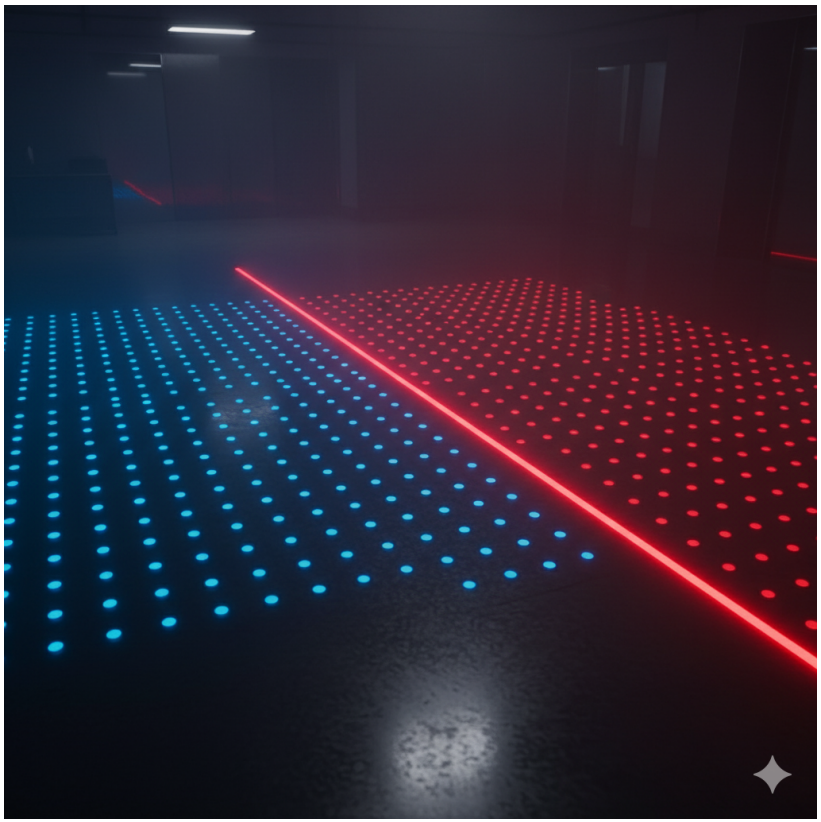


- En 1D: un **punto** divide la recta.
- En 2D: una **línea** separa el plano.
- En 3D: un **plano** divide el espacio.
- En más dimensiones: una **barrera abstracta** separa regiones según una regla lineal.

Ejemplos de hiperplanos en 1D y 2D

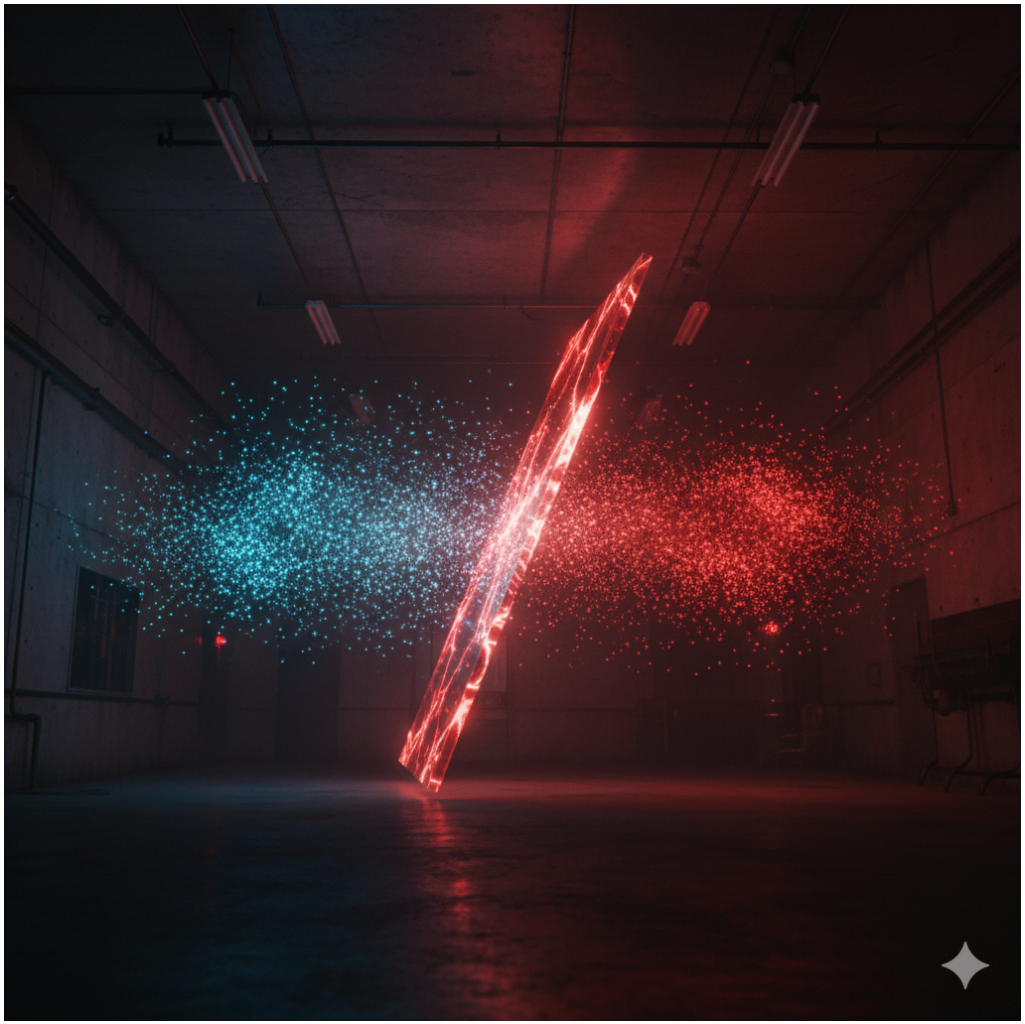


Hiperplano en 1D — un punto que divide la recta.



Hiperplano en 2D — línea que separa el plano.

Ejemplo de hiperplano en 3D



Hiperplano en 3D — plano que divide el espacio.

El descubrimiento del margen

Dividir no bastaba. Los datos más peligrosos eran los que quedaban justo en el borde, vibrando entre realidades.

Los científicos establecieron un principio: la frontera debía tener **margen**, un espacio de seguridad donde ningún punto pudiera existir sin definirse.

Cuanto más ancho el margen, más estable sería Hawkins.

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2}\|w\|^2 \\ \text{sujeto a} \quad & y_i(w^\top x_i + b) \geq 1, \quad i = 1, \ldots, n \end{aligned}$$

El modelo que maximiza el margen ofrece la mayor protección frente al caos.

Contenido

1 Soporte Vectorial en Hawkins

2 Elementos clave

3 Support Vector Regression (SVR)

4 De vuelta a Hawkings

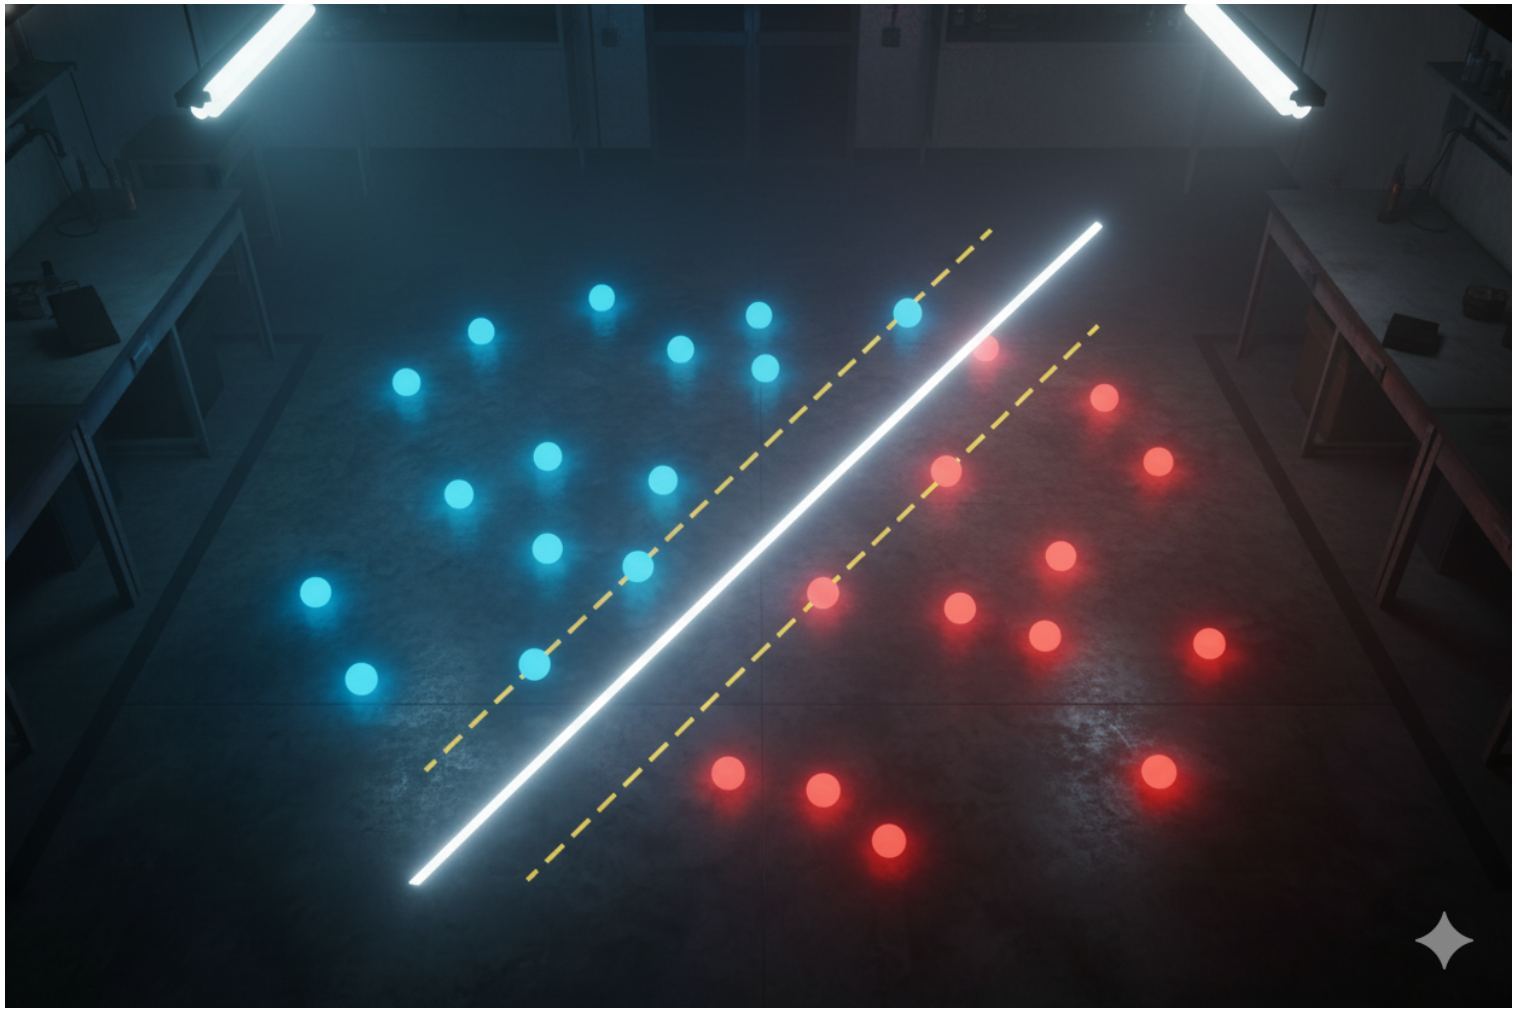
Los vectores de soporte

No todos los puntos determinaban la frontera.
Solo unos pocos tocaban el límite: los **vectores de soporte**.

Mover uno solo bastaba para alterar el hiperplano.
Los demás puntos eran irrelevantes.
En Hawkins, los llamaban *los puntos sensibles del tejido del universo*.

Cumplen $y_i(w^\top x_i + b) = 1$ y definen la posición exacta del margen.
Si uno se mueve, toda la frontera cambia.

Los vectores de soporte



Hiperplanos en múltiples dimensiones

Cada nueva característica —energía, tiempo, vibración— añadía una dimensión.
La frontera se convirtió en un **hiperplano** que dividía regiones complejas:

$$f(x) = \text{sign}(w^\top x + b)$$

El signo de $f(x)$ indica la clasificación: positiva o negativa.

El vector w marca la dirección perpendicular al plano.
Cada dimensión adicional convierte una simple línea en una barrera abstracta.

Distancia a la frontera

La distancia al hiperplano se mide como:

$$\frac{|w^\top x + b|}{\|w\|}$$

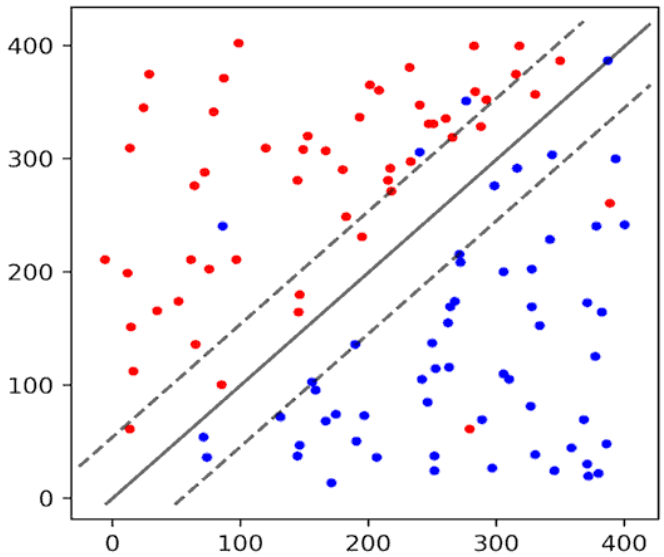
Valores altos indican clasificaciones seguras; valores bajos, incertidumbre.
Los puntos sobre el margen definen el equilibrio del modelo.

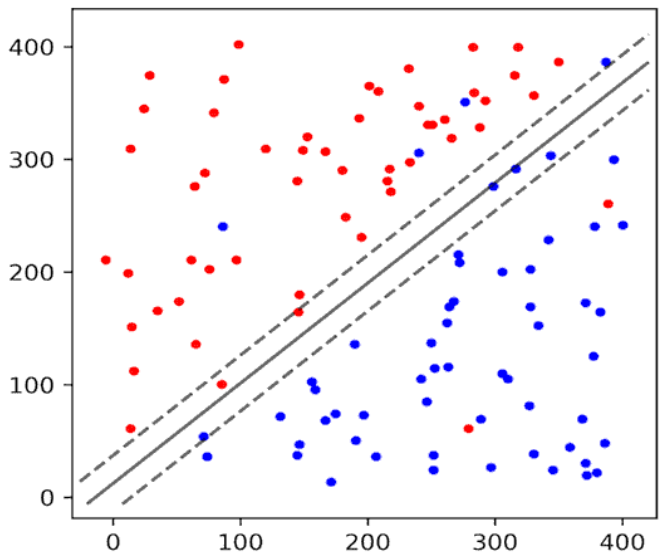
Margen suave y parámetro C

En entornos reales los datos son ruidosos, y algunas observaciones no pueden separarse sin errores. Para ello se introducen variables de holgura ξ_i para permitir violaciones del margen.

El parámetro C controla el equilibrio entre rigidez y flexibilidad:

- C alto $\rightarrow$ frontera rígida, poco tolerante.
- C bajo $\rightarrow$ frontera flexible, tolerante al ruido.





Margen suave y parámetro C

El modelo minimiza:

$$\frac{1}{2}\|w\|^2 + C\sum_i \xi_i$$

El primer término controla el ancho del margen; el segundo penaliza los errores.

La elección de (C) determina qué tanto se prioriza la precisión frente a la generalización.

Función de pérdida y energía del modelo

Cada error se mide con la **función hinge loss**:

$$\ell(y, f) = \max(0, 1 - yf)$$

Si un punto está bien clasificado y fuera del margen, la pérdida es cero. Cerca del límite, la penalización aumenta.

El sistema minimiza la energía total:

$$\min \frac{1}{2}\|w\|^2 + C \sum_i \xi_i$$

El equilibrio final representa el estado de mínima energía del modelo.

Estabilidad y generalización

Un margen amplio implica mayor estabilidad.
Modelos dependientes de pocos casos se vuelven frágiles.

El margen constante frente a nuevos datos demuestra **capacidad de generalizar**.

Pequeñas variaciones no deben alterar significativamente la frontera.

Aplicaciones

- Detección de señales anómalas.
- Clasificación de correos falsos.
- Identificación de comportamientos atípicos.
- Separación de proteínas mutantes.
- Análisis de texto: lenguaje natural vs generado.

En todos los casos, el objetivo es hallar una frontera clara y estable.

Limitaciones del modelo lineal

El modelo lineal falla cuando:

- Las clases no pueden separarse con una línea recta.
- Los datos presentan formas no lineales (espirales, círculos).
- Aumentar dimensiones no mejora la separación.
- El margen se reduce por ruido o no linealidad.

Contenido

1. Soporte Vectorial en Hawkins
2. Elementos clave
3. Support Vector Regression (SVR)
4. De vuelta a Hawkings

El tubo de tolerancia ε

En **SVR** se estima una función lineal:

$$f(x) = w^\top x + b$$

y se define un **tubo de tolerancia** alrededor de ella controlado por el parámetro ε.

La idea central es:

$$|y_i - f(x_i)| \leq \varepsilon$$

Si un punto (x_i, y_i) cae dentro de ese tubo, el error se considera aceptable y **no se penaliza**.

El tubo de tolerancia ε

El parámetro ε determina el **ancho del tubo**:
valores pequeños hacen el tubo más estrecho (modelo más exigente),
valores grandes hacen el tubo más ancho (modelo más tolerante a pequeñas desviaciones).



Vectores de soporte y holgura

Solo los puntos que quedan **fuera** del tubo influyen en el modelo:
estos son los **vectores de soporte** en regresión.

Para medir cuánto se salen del tubo se introducen las variables de holgura:

$$\xi_i \geq 0, \quad \xi_i^* \geq 0$$

y las restricciones quedan:

$$y_i - f(x_i) \leq \varepsilon + \xi_i$$
$$f(x_i) - y_i \leq \varepsilon + \xi_i^*$$

Los puntos con $\xi_i = \xi_i^* = 0$ están dentro del tubo;
los que tienen $\xi_i > 0$ o $\xi_i^* > 0$ están fuera y se vuelven vectores de soporte.

Parámetro C y función objetivo

El parámetro C controla cuánto importan los puntos fuera del tubo.
Valores altos de C fuerzan a reducir la holgura (ξ_i, ξ_i^*),
valores bajos aceptan más desviaciones para obtener un modelo más simple.

El problema que resuelve SVR es:

$$\min_{w,b,\xi,\xi^*} \ \frac{1}{2}\|w\|^2 + C\sum_i(\xi_i + \xi_i^*)$$

sujeto a las restricciones anteriores.

En forma intuitiva:
SVR busca una función $f(x)$ **lo más plana posible** (término $\frac{1}{2}\|w\|^2$)
que coloque **la mayoría de los puntos dentro del tubo** definido por ε,
mientras mantiene bajo control las desviaciones grandes mediante C.

Contenido

1. Soporte Vectorial en Hawkins
2. Elementos clave
3. Support Vector Regression (SVR)
4. De vuelta a Hawkings

El equilibrio inestable

El campo de contención mantenía la frontera entre realidades, pero cada punto nuevo alteraba su energía.

Los errores liberaban *hinge loss*, aumentando la tensión.
El regulador C controlaba la rigidez del sistema:

Valores altos $\rightarrow$ frontera dura pero frágil.
Valores bajos $\rightarrow$ frontera flexible y resistente.

El equilibrio consistía en mantener el margen máximo con mínima energía.

El nuevo experimento

El campo comenzó a deformarse más allá de todo control.

Las líneas rectas ya no podían contener los datos: el espacio mismo se curvaba.

Los científicos comprendieron que no bastaba con ajustar el margen. Había que **cambiar el espacio**, no la frontera.

En los registros del laboratorio apareció una sola palabra: **Kernel**. Un método capaz de doblar la realidad para separar lo inseparable.

