Métricas en Clásificación

La casa de los algoritmos, donde Precision cocina excusas, Recall planea complots y F1 intenta mediar sin éxito

Daniel Barajas Higuera

MLEARN



Contenido

1. Introduccion
2. Metricas
3. Ejercicio

Medidas de Rendimiento

- Las medidas de rendimiento son métricas utilizadas para evaluar la calidad y efectividad de un clasificador en tareas de clasificación.
- Estas medidas proporcionan información sobre cuán bien el clasificador está realizando sus predicciones.
- Evaluar un clasificador suele ser más complejo que medir el error en regresión, ya que los distintos tipos de error no tienen el mismo impacto según el contexto.

Medidas de Rendimiento en Clasificación

Las principales medidas de rendimiento en tareas de clasificación son:

- **Exactitud (Accuracy)**
- **Precisión (Precision)**
- **Sensibilidad (Recall o Tasa de verdaderos positivos)**
- **Especificidad (Tasa de verdaderos negativos)**
- **F1-Score**
- **ROC-AUC (Área bajo la curva)**

Para calcular cada una de estas métricas es necesaria la matriz de confusión.

Matriz de Confusión

		Predicción	
		Negativa	**Positiva**
Real	**Negativo**	**True Negative (TN)**  .	**False Positive (FP)**  Error tipo I
	Positivo	**False Negative (FN)**  Error tipo II	**True Positive (TP)**  .

Contenido

1 Introduccion

2 Metricas

3 Ejercicio

Métricas de Clasificación

La **matriz de confusión** es el insumo central para evaluar un clasificador. A partir de sus valores se construyen distintas métricas que ofrecen perspectivas complementarias sobre el desempeño.

- **Exactitud (Accuracy):** porcentaje global de aciertos.
- **Precisión (Precision):** confiabilidad de las predicciones positivas.
- **Sensibilidad (Recall):** cobertura de los positivos reales.
- **Especificidad (Specificity):** detección correcta de negativos.
- **F1-Score:** equilibrio entre precisión y sensibilidad.

Cada métrica responde a una dimensión distinta del problema y ninguna por sí sola es suficiente.

De la Matriz a las Métricas

Con la **matriz de confusión** definida, calcular las métricas se reduce a combinar sus entradas mediante operaciones aritméticas sencillas.



Exactitud (Accuracy)

¿Qué es? Mide la proporción de predicciones correctas sobre el total de predicciones realizadas.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

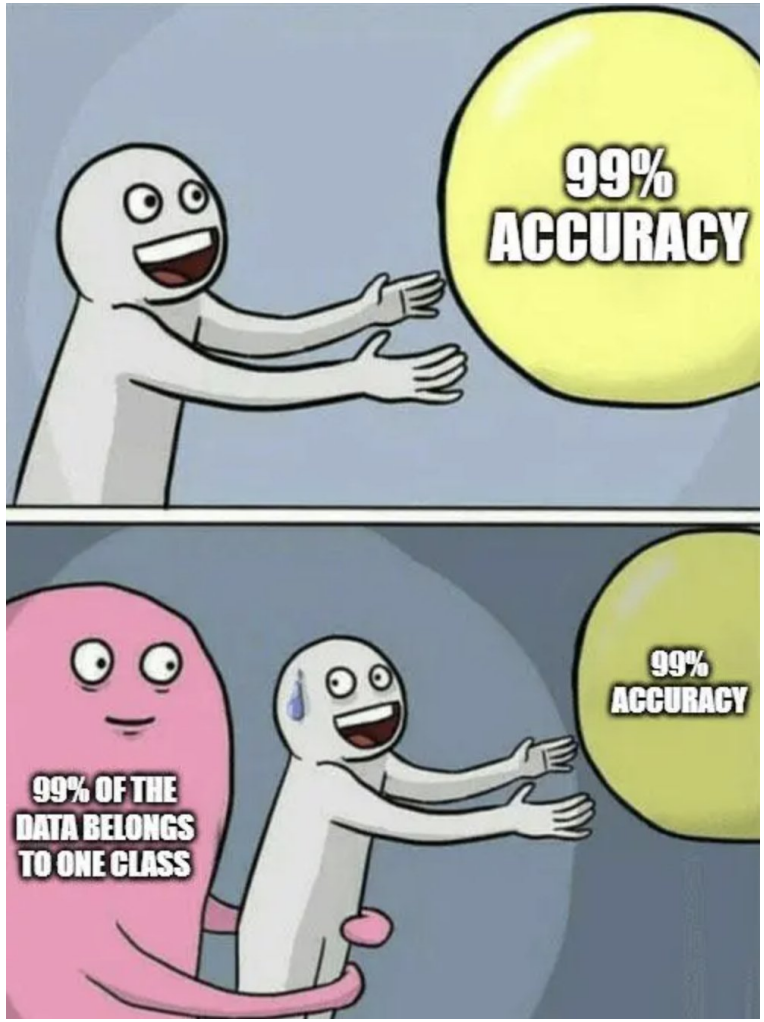
¿Cuándo es útil? Cuando las clases están balanceadas, es decir, cuando los casos positivos y negativos tienen cantidades similares.

		Predicción	
		0	**1**
Real	**0**	TN	FP
	1	FN	TP

Exactitud (Accuracy) – Ejemplos

Ejemplo 1 En un reality como *Gran Hermano*, si los espectadores aciertan el 80 % de las veces al identificar quién merece ser expulsado, la exactitud es alta: la percepción coincide con la realidad del juego.

Ejemplo 2 En un modelo de reconocimiento de dígitos escritos a mano (como MNIST), la exactitud es útil porque las clases —del 0 al 9— están distribuidas de forma equilibrada. Si el modelo acierta el 90 % de los dígitos, su desempeño general es sólido.



Precisión (Precision)

¿Qué es? Evalúa la proporción de verdaderos positivos entre todos los positivos predichos.

$$\text{Precision} = \frac{TP}{TP + FP}$$

¿Cuándo es útil? Cuando el costo de los falsos positivos es alto, es decir, cuando señalar algo como positivo por error genera consecuencias o pérdidas.

		Predicción	
		0	**1**
Real	**0**	TN	FP
	1	FN	TP

Precisión (Precision) – Ejemplos

Ejemplo 1 Un inversionista escucha decenas de propuestas llenas de promesas vacías. Si apuesta por todos los que suenan convincentes, pronto estará en bancarrota. La precisión consiste en detectar solo los proyectos con verdadero potencial y dejar fuera el humo disfrazado de innovación.

Ejemplo 2 En un proceso de selección de talento, un algoritmo que marca como "aptos" a candidatos sin las competencias necesarias provoca entrevistas desperdiciadas y decisiones erróneas. La precisión implica identificar únicamente a los postulantes que realmente cumplen con el perfil.

EL ALGORITMO RECOMIENDA AL PRIMO DEL JEFE COMO CANDIDATO TOP



ES UN NO PARA MÍ, ESTOY FUERA

Sensibilidad (Recall)

¿Qué es? Mide la proporción de verdaderos positivos detectados entre todos los casos positivos reales.

$$\text{Recall} = \frac{TP}{TP + FN}$$

¿Cuándo es útil? Cuando el costo de no detectar casos positivos es alto, es decir, cuando los falsos negativos son más peligrosos que los falsos positivos.

		Predicción	
		0	**1**
Real	**0**	TN	FP
	1	FN	TP

Sensibilidad (Recall) – Ejemplos

Ejemplo 1 Un entrenador escucha múltiples voces tras un telón. Si no reconoce a todos los talentos y deja pasar a una gran cantante, pierde la oportunidad para siempre. Lo importante no es equivocarse con alguno, sino no dejar escapar a los mejores.

Ejemplo 2 En un sistema de diagnóstico médico que analiza radiografías para detectar cáncer, la sensibilidad es crítica: un solo falso negativo significa dejar sin atención a un paciente enfermo, con consecuencias potencialmente irreversibles.



Especificidad (Specificity)

¿Qué es? Mide la proporción de verdaderos negativos correctamente identificados entre todos los casos negativos reales.

$$\text{Specificity} = \frac{TN}{TN + FP}$$

¿Cuándo es útil? Cuando es fundamental reconocer con precisión los casos negativos y evitar falsas alarmas que generen ruido o desconfianza.

		Predicción	
		0	**1**
Real	**0**	TN	FP
	1	FN	TP

Especificidad (Specificity) – Ejemplos

Ejemplo 1 En *Alerta Aeropuerto*, los agentes deben distinguir entre pasajeros realmente sospechosos y viajeros comunes. Si confunden cada frasco de champú con contrabando, el operativo se vuelve un caos. La especificidad representa esa capacidad de no emitir falsas alarmas y centrarse solo en las amenazas reales.

Ejemplo 2 En un curso donde el 90 % de los estudiantes aprueba, un modelo ingenuo podría predecir que todos pasarán. Aunque parecería exitoso por la cantidad de aciertos, sería incapaz de identificar a quienes realmente reprueban. Una alta especificidad permite reconocer correctamente a los que no aprobaron, en lugar de asumir que todo está bien.

CUANDO LAS MÉTRICAS DAN 99 % DE EXACTITUD...



PORQUE TODOS SON NEGATIVOS

F1-Score

¿Qué es? Combina precisión y sensibilidad en una sola medida de equilibrio. El F1 es la **media armónica** de ambas métricas: castiga duramente los valores bajos y solo es alto cuando las dos son buenas.

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

¿Por qué media armónica? A diferencia del promedio común, la media armónica se reduce drásticamente si una de las dos partes falla. Un modelo con precisión alta pero recall bajo (o viceversa) nunca obtendrá un F1 decente.

F1-Score – Ejemplos

Ejemplo 1 En *La Casa de los Famosos*, el éxito depende de dos cosas: nominar a los enemigos correctos y no enemistarse con todos. Acertar sin control lleva al caos; ser prudente pero ciego al conflicto también fracasa. El F1 representa ese equilibrio entre precisión y sensibilidad: saber atacar cuando toca y callar cuando conviene.

Ejemplo 2 En la clasificación de mensajes de emergencia en redes sociales, se necesita detectar los casos urgentes sin etiquetar por error demasiados mensajes normales. El F1 equilibra ambas prioridades: detectar lo importante sin disparar falsas alarmas.

CUANDO EXPONES ORGULLOSO QUE TU MODELO TIENE RECALL PERFECTO



Y EL PROFESOR PIDE EL F1... Y ESA ES TU NOTA

Contenido

1 Introduccion

2 Metricas

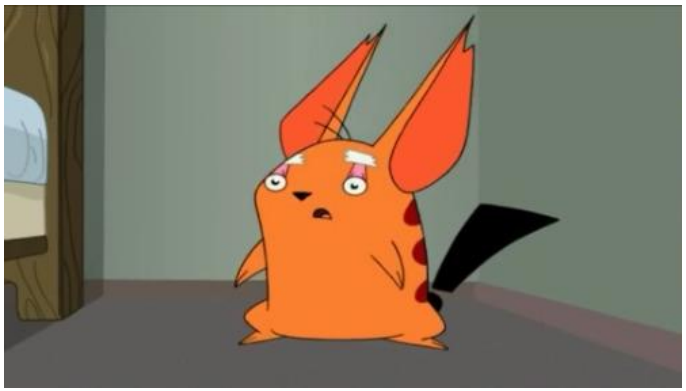
3 Ejercicio

Ejercicio: Probabilidades y Etiquetas

Se tiene un conjunto de datos binario con probabilidades predichas para cada instancia. A partir de un umbral de 0.5, se deben asignar etiquetas y construir la matriz de confusión.

Etiqueta = 1 (Positiva)	**Etiqueta = 0 (Negativa)**
0.95	0.92
0.90	0.89
0.80	0.70
0.75	0.48
0.65	0.46
0.55	0.45
0.40	0.25
0.30	0.15
0.20	0.05
0.10	0.01

FÍJENSE BIEN EN LAS PROBABILIDADES



PORQUE DE ESO DEPENDEN LAS ETIQUETAS PREDICHAS

Ejercicio: Calcular las Métricas de Rendimiento

Paso 1: Construir la matriz de confusión con umbral = 0.5.

	Predicción Negativa	**Predicción Positiva**
Etiqueta = 0	TN	FP
Etiqueta = 1	FN	TP

Paso 2: A partir de la matriz de confusión, calcular las métricas de desempeño.

Umbral	**TP**	**FP**	**TN**	**FN**
0.5				

Medidas de Rendimiento

		Predicción	
		0	**1**
Real	**0**	TN	FP
	1	FN	TP

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

$$\text{Specificity} = \frac{TN}{TN + FP}$$

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Medidas de Rendimiento

