El Distrito Kabuki de la Regresión

Un episodio donde tres equipos descubren que el verdadero enemigo nunca fue el modelo, sino la consulta mal armada.

Daniel Barajas Higuera

MLEARN

Proyecto de Regresión con Restbase

En este episodio, tres equipos de estudiantes son arrojados sin piedad a una base de datos relacional real alojada en el repositorio CTU Relational Learning Repository.
No hay archivos milagrosamente limpios ni datasets domesticados por la benevolencia divina.
Hay tablas, llaves, consultas SQL y restaurantes que deben ser convertidos en variables sin que nadie pierda del todo la estabilidad mental.

Proyecto de Regresión con Restbase

1. Problema de regresión supervisada.
2. Datos extraídos directamente con SQL.
3. Tres equipos de trabajo.
4. Cinco hitos con rotación de roles.
5. Rotación de integrantes en cada hito.
6. Entrega grupal y sustentación individual.

Hito 1: El Arco del SQL que Nadie Quería

La historia comienza como siempre empiezan las tragedias académicas: con una base de datos que nadie ha leído y un entusiasmo sospechosamente injustificado.

Aquí no se recibe un archivo bonito y domesticado.

Se recibe un sistema relacional con tablas conectadas, llaves y columnas que exigen respeto.

La primera batalla consiste en entender qué demonios hay en la base y cómo convertirlo en un dataset útil.

Hito 1: El Arco del SQL que Nadie Quería

1. Conectarse a la base `restbase`.
2. Identificar tablas, llaves y relaciones.
3. Construir consultas con `JOIN`.
4. Definir la variable objetivo `review`.
5. Limpiar, codificar y separar train, validation y test.

Hito 2: La Humillación del Baseline

Cuando por fin existe una tabla analítica, aparece la siguiente bofetada pedagógica: el baseline.

Antes de invocar modelos con nombres pomposos, toca probar si una solución simple ya hace algo decente.

La media y la regresión lineal entran en escena como esos personajes secundarios que parecen ridículos pero terminan siendo los únicos funcionales.

Si el modelo complejo no supera esto, todo el espectáculo posterior será puro maquillaje estadístico.

Hito 2: La Humillación del Baseline

1. Definir una predicción base con la media.
2. Entrenar una regresión lineal.
3. Evaluar sobre validation.
4. Calcular MAE, RMSE y R^2.
5. Analizar errores y residuos.

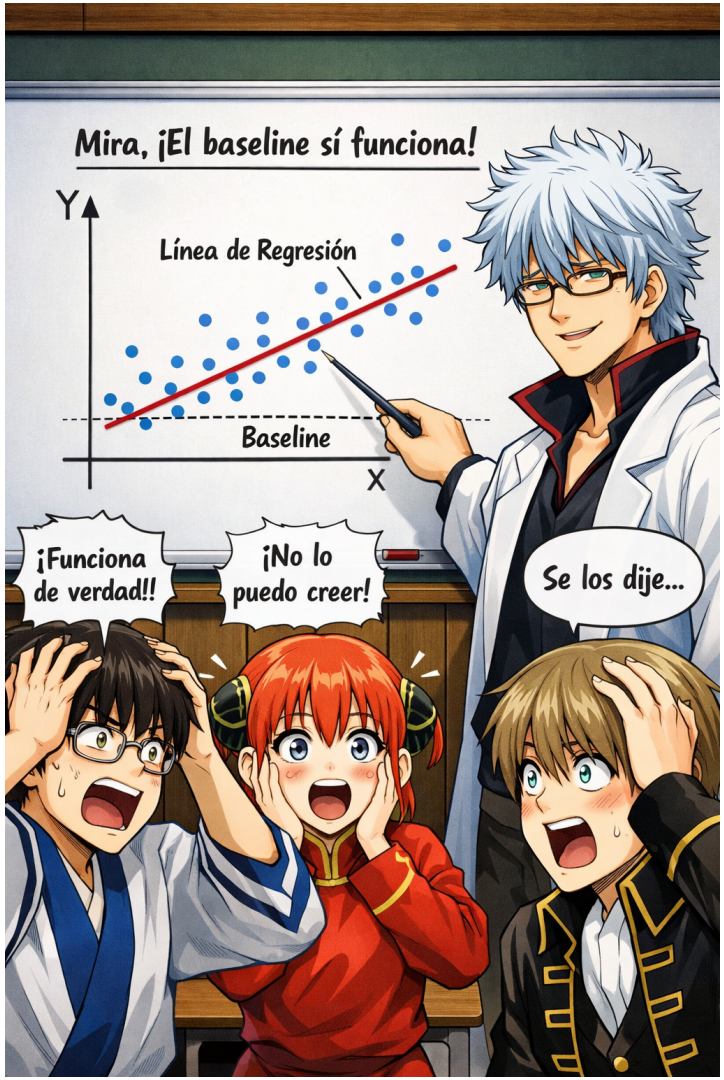

Hito 3: El Modelo Más Fuerte del Distrito Kabuki

Superado el baseline, llega el momento de probar un modelo con más ambición y menos modestia.

Aquí el profesor define una familia de modelos razonable y los equipos deben entrenarla sin caer en el circo de mover hiperparámetros como si fueran amuletos mágicos.

La pregunta no es cuál modelo suena más impresionante.

La pregunta es cuál mejora de verdad la predicción sin convertir el análisis en una secta de fe computacional.

Hito 3: El Modelo Más Fuerte del Distrito Kabuki

1. Entrenar un modelo base supervisado.
2. Usar alternativas como Ridge o árboles.
3. Ajustar el modelo sobre train.
4. Evaluar en validation.
5. Comparar contra el baseline lineal.

Hito 4: El Festival del Ajuste Sospechosamente Específico

Todo proyecto llega a la fase donde alguien propone cambiar veinte cosas al tiempo y luego finge que eso fue metodología.

Este hito existe para impedir semejante desastre.

Cada variante debe responder a una hipótesis clara: imputación, codificación, selección de variables o regularización.

Se experimenta con control, no con desesperación disfrazada de creatividad.

Hito 4: El Festival del Ajuste Sospechosamente Específico

1. Probar estrategias de imputación.
2. Comparar codificaciones de variables categóricas.
3. Evaluar selección de variables.
4. Ajustar hiperparámetros del modelo.
5. Construir una tabla comparativa de resultados.

Hito 5: La Guerra Final por el Test Set

En el último arco se integra todo el pipeline y se toma la decisión final.

Se elige el mejor modelo según validation y luego se enfrenta al test set una sola vez, como corresponde cuando todavía queda algo de dignidad metodológica.

Después de eso solo queda redactar conclusiones, sostenerlas con argumentos y sobrevivir a la sustentación individual.

Una escena clásica de Gintama: ruido, caos, gritos y, por accidente, aprendizaje real.

Hito 5: La Guerra Final por el Test Set

1. Consolidar el pipeline completo.
2. Seleccionar el mejor modelo.
3. Evaluar una sola vez sobre test.
4. Redactar conclusiones técnicas.
5. Realizar sustentación individual.

Organización del Trabajo en Equipo

Como toda comedia seria, este proyecto necesita una estructura ridículamente estricta para no colapsar.

Cada integrante asume un rol distinto en cada hito y luego rota.

Además, en cada etapa deben rotar integrantes entre los tres equipos, de modo que el conocimiento circule y nadie pueda esconderse cinco semanas fingiendo que solo sabía hacer una consulta.

La idea es que cada equipo cambie, se reconfigure y sobreviva al caos con algo parecido a comprensión real.

Organización del Trabajo en Equipo

1. Tres equipos trabajan sobre el mismo problema.
2. Roles definidos y rotados en cada hito.
3. En cada hito rota al menos un integrante por equipo.
4. La rotación se hace de forma cíclica entre equipos.
5. Sustentación individual para verificar dominio real.

Objetivo Pedagógico

Detrás del absurdo hay una intención bastante concreta.

El proyecto busca que se entienda el flujo completo de un problema de machine learning con datos relacionales reales.

No basta con correr un modelo y celebrar una métrica.

Hay que saber extraer, preparar, justificar, evaluar y defender cada decisión sin esconder la incompetencia detrás de gráficos bonitos.

Advertencia

- Si el SQL sale mal, no hay dataset.
- Si el baseline supera al modelo final, no hay dignidad.
- Si el equipo se desintegra en plena rotación, pierde el proyecto.
- Si el experimento no funciona, quedan condenados a explicar que todo empezó con tres tablas, un `JOIN` mal hecho y una regresión que juraba predecir la satisfacción de clientes mientras en realidad estaba modelando el colapso emocional del grupo.