El Distrito Kabuki Supervisado

Un episodio donde tres equipos descubren que el verdadero enemigo nunca fue el modelo, sino la consulta mal armada.

Daniel Barajas Higuera

MLEARN

Contenido

1. Regresión
2. Los algoritmos fallidos
3. Clasificación

Proyecto de Regresión con Restbase

En este episodio, tres equipos de estudiantes son arrojados sin piedad a una base de datos relacional real alojada en el repositorio CTU Relational Learning Repository.
No hay archivos milagrosamente limpios ni datasets domesticados por la benevolencia divina.
Hay tablas, llaves, consultas SQL y restaurantes que deben ser convertidos en variables sin que nadie pierda del todo la estabilidad mental.

Proyecto de Regresión con Restbase

1. Problema de regresión supervisada.
2. Datos extraídos directamente con SQL.
3. Tres equipos de trabajo.
4. Cinco hitos con rotación de roles.
5. Rotación de integrantes en cada hito.
6. Entrega grupal y sustentación individual.

Hito 1: El Arco del SQL que Nadie Quería

La historia comienza como siempre empiezan las tragedias académicas: con una base de datos que nadie ha leído y un entusiasmo sospechosamente injustificado.

Aquí no se recibe un archivo bonito y domesticado.

Se recibe un sistema relacional con tablas conectadas, llaves y columnas que exigen respeto.

La primera batalla consiste en entender qué demonios hay en la base y cómo convertirlo en un dataset útil.

Hito 1: El Arco del SQL que Nadie Quería

1. Conectarse a la base `restbase`.
2. Identificar tablas, llaves y relaciones.
3. Construir consultas con `JOIN`.
4. Definir la variable objetivo `review`.
5. Limpiar, codificar y separar train, validation y test.

Hito 2: La Humillación del Baseline

Cuando por fin existe una tabla analítica, aparece la siguiente bofetada pedagógica: el baseline.

Antes de invocar modelos con nombres pomposos, toca probar si una solución simple ya hace algo decente.

La media y la regresión lineal entran en escena como esos personajes secundarios que parecen ridículos pero terminan siendo los únicos funcionales.

Si el modelo complejo no supera esto, todo el espectáculo posterior será puro maquillaje estadístico.

Hito 2: La Humillación del Baseline

1. Definir una predicción base con la media.
2. Entrenar una regresión lineal.
3. Evaluar sobre validation.
4. Calcular MAE, RMSE y R^2.
5. Analizar errores y residuos.

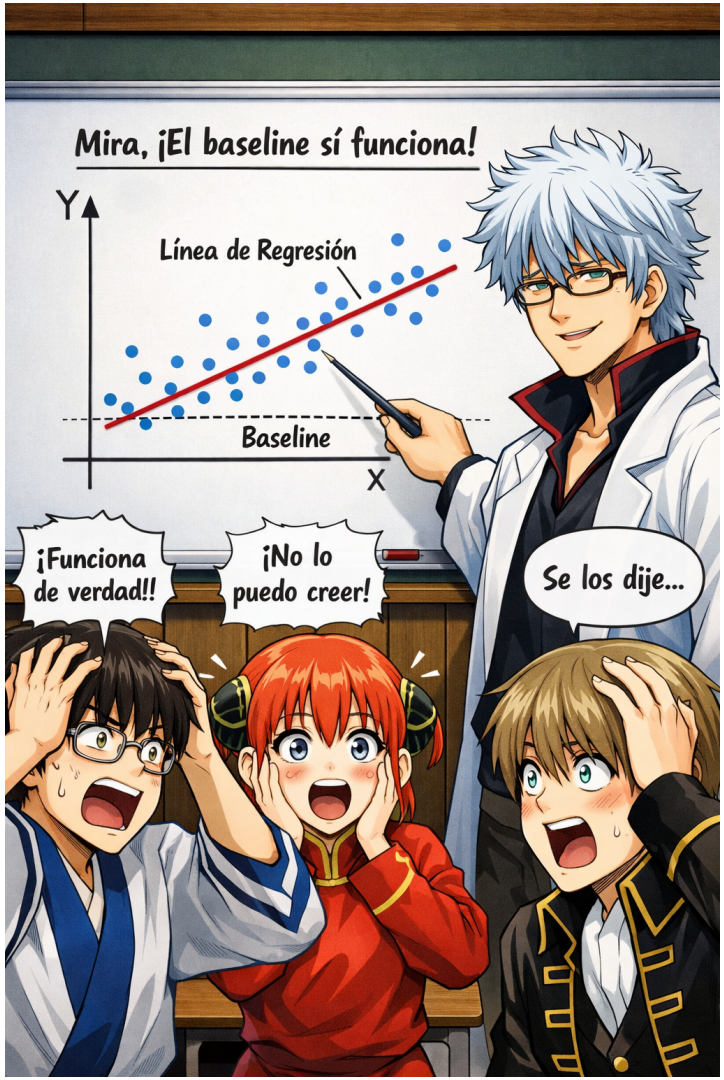

Hito 3: El Modelo Más Fuerte del Distrito Kabuki

Superado el baseline, llega el momento de probar un modelo con más ambición y menos modestia.

Aquí el profesor define una familia de modelos razonable y los equipos deben entrenarla sin caer en el circo de mover hiperparámetros como si fueran amuletos mágicos.

La pregunta no es cuál modelo suena más impresionante.

La pregunta es cuál mejora de verdad la predicción sin convertir el análisis en una secta de fe computacional.

Hito 3: El Modelo Más Fuerte del Distrito Kabuki

1. Entrenar un modelo base supervisado.
2. Usar alternativas como Ridge o árboles.
3. Ajustar el modelo sobre train.
4. Evaluar en validation.
5. Comparar contra el baseline lineal.

Contenido

1 Regresión

2 Los algoritmos fallidos

3 Clasificación

El Gran Evento: Presentación en Auditorio

Al final del Hito 3, los tres equipos fueron convocados al auditorio.

No para viernes de película, sino para mostrar sus resultados.

Y lo que apareció en pantalla ante todos fue una catástrofe de proporciones épicas:

- $R^2 < 0$ en más de un modelo. Negativo.
- RMSE mayor que la varianza de la variable objetivo.
- Un pipeline que codificó variables *antes* del split. Métricas ficticias.
- Un `JOIN` que duplicó 2.000 registros sin que nadie lo notara.

El Silencio Después de las Métricas

El auditorio quedó en silencio.

No el silencio de la comprensión.

El silencio de quien acaba de ver su propio `pipeline` colapsar en público.

La Decisión: Nueva Rotación y Auditoría EDA

Se ejecuta una nueva rotación de equipos.

El primer paso es auditar el Análisis Exploratorio de Datos (EDA).

Revisar las variables de tipo de comida.

Verificar extracción de información adicional de `label` (ejemplo: identificar franquicias).

Explorar alternativas analíticas al One-Hot Encoding para manejar alta cardinalidad.

Contenido

1 Regresión

2 Los algoritmos fallidos

3 Clasificación

Actualización de Emergencia desde el Frente Académico

En toda buena saga hay un momento en que el guion se rompe.

Gintama lo hace a propósito.

Nosotros lo hacemos porque la universidad también es un sistema relacional con `JOIN`s mal hechos, llaves foráneas rotas y tablas que nadie documentó.

Lo que estaba planeado ya no aplica.

Lo que sigue es mejor, aunque nadie lo eligió voluntariamente.

Reformulación a Problema de Clasificación

El problema se transforma en clasificación binaria.

Se exige proponer y justificar la construcción de la variable objetivo `recommended`.

Opciones a evaluar:

- Utilizar la media estadística y verificar el desbalance de clases resultante.
- Utilizar la mediana estadística para forzar un balance estructural.

La decisión técnica debe documentarse antes del modelado.

Hito 4: Búsqueda de Hiperparámetros y Clasificación

1. Ejecutar separación estricta en entrenamiento, validación y prueba.
2. Asignar un algoritmo de clasificación a cada integrante.
3. Determinar y justificar la métrica de evaluación más adecuada para el problema operativo.
4. Ejecutar Grid Search. Cada integrante evalúa 8 variantes de hiperparámetros sobre el conjunto de validación.
5. Seleccionar el mejor modelo por integrante basándose en la métrica justificada.

Hito 5: Evaluación Final y Sustentación

1. Consolidar el pipeline: SQL → EDA → clasificación.
2. Comparar los modelos seleccionados por cada integrante.
3. Evaluar el modelo definitivo **una sola vez** sobre el conjunto de prueba (test).
4. Comparar la utilidad analítica entre el enfoque de regresión y el de clasificación.
5. Redactar conclusiones técnicas.
6. Sustentación individual del flujo completo.

Pregunta Central de Sustentación

"¿Por qué este modelo y no otro?"

El accuracy general o el ensayo empírico no constituyen justificaciones válidas.

Se exige demostrar la siguiente conexión lógica:

Problema de negocio $\rightarrow$ **Métrica elegida** $\rightarrow$ **Modelo seleccionado** $\rightarrow$ **Resultados en test**.

Romper esta cadena invalida el análisis.

Advertencia Final de Evaluación

- Fallar en la ingeniería de características condena el modelo a la irrelevancia absoluta.

Advertencia Final de Evaluación

- Fallar en la ingeniería de características condena el modelo a la irrelevancia absoluta.
- Binarizar o seleccionar métricas sin justificación destruye el problema desde su concepción.

Advertencia Final de Evaluación

- Fallar en la ingeniería de características condena el modelo a la irrelevancia absoluta.
- Binarizar o seleccionar métricas sin justificación destruye el problema desde su concepción.
- Violar el conjunto de prueba aniquila de forma irreversible cualquier validez técnica.

Advertencia Final de Evaluación

- Fallar en la ingeniería de características condena el modelo a la irrelevancia absoluta.
- Binarizar o seleccionar métricas sin justificación destruye el problema desde su concepción.
- Violar el conjunto de prueba aniquila de forma irreversible cualquier validez técnica.
- El desconocimiento del pipeline garantiza reprobación fulminante, y nos vemos el próximo semestre en MLEARN.

Advertencia Final de Evaluación

- Fallar en la ingeniería de características condena el modelo a la irrelevancia absoluta.
- Binarizar o seleccionar métricas sin justificación destruye el problema desde su concepción.
- Violar el conjunto de prueba aniquila de forma irreversible cualquier validez técnica.
- El desconocimiento del pipeline garantiza reprobación fulminante, y nos vemos el próximo semestre en MLEARN.
- La incomprensión de estos fundamentos asegura que aunque apruebe, el próximo semestre Liliana en DEEPLN les va a dar como rata en balde.

Advertencia Final de Evaluación

- Fallar en la ingeniería de características condena el modelo a la irrelevancia absoluta.
- Binarizar o seleccionar métricas sin justificación destruye el problema desde su concepción.
- Violar el conjunto de prueba aniquila de forma irreversible cualquier validez técnica.
- El desconocimiento del pipeline garantiza reprobación fulminante, y nos vemos el próximo semestre en MLEARN.
- La incomprensión de estos fundamentos asegura que aunque apruebe, el próximo semestre Liliana en DEEPLN les va a dar como rata en balde.

"Todo lo que no limpias. . . termina volviendo por ti."